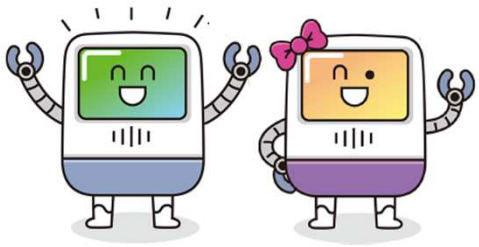
딥러닝

6장 오차 역전파



06

오차 역전파

학습목차

01 활성화 함수와 신경망의 가중치 조절
02 역전파 알고리즘에 대한 직관적 이해
03 계산 그래프 실습하기
04 시그모이드 계층의 역전파
05 ReLU 함수

학습목표

- 경사하강법으로 다층 퍼셉트론의 최적값을 구하는 방법을 알아본다.
- 다층 신경망의 가중치를 갱신하기 위하여 오차 역전파를 사용하는 이유를 이해한다.
- 다층 신경망의 각 계산 노드에서 지역 기울기를 사용하는 이유를 이해한다.
- 오차 역전파를 통해서 신경망의 가중치를 효율적으로 학습할 수 있음을 이해한다.
- 신경망의 활성화 함수로 시그모이드 함수보다 ReLU 함수가 더 나은 결과를 만드는 이유를 이해한다.



- 활성화 함수와 신경망의 가중치 조절
  - 다층 퍼셉트론의 학습 단계
  - 순전파와 역전파
  - 오차 역전파 알고리즘의 간략한 역사
- 역전파 알고리즘에 대한 직관적 이해
  - 계산 그래프를 이용한 오차 역전파의 이해
  - 계산 그래프의 순방향 계산
  - 계산 그래프의 역방향 계산
- 계산 그래프 실습하기
  - 곱셈 노드, 덧셈 노드의 미분과 역전파 과정
  - 전체 계산 그래프를 만들기
  - 입력 노드에 대한 출력값의 영향을 어떻게 활용할까
  - 오차와 계산 그래프
- 시그모이드 계층의 역전파
  - 시그모이드 함수의 미분과 계산 그래프
  - 퍼셉트론의 구조와 계산 그래프 그리고 오차 역전파의 혁신
- ReLU 함수
  - 활성화 함수의 중요성
  - ReLU 함수를 그려보자

- 다층 퍼셉트론의 학습 단계
  - **경사하강법**gradient descent과 이를 이용한 다층 퍼셉트론의 학습 단계

단계 1: 임의의 초기 가중치를 가진 퍼셉트론에 입력 데이터를 넣어 준다.

단계 2: 입력값과 가중치를 이용하여 퍼셉트론의 노드 각각에 대한 가중합을 계산한다.

단계 3: 노드 각각의 가중합을 구하고 이를 활성화 함수의 입력으로 넣어 준다.

단계 4: 단계 2와 단계 3의 과정을 출력 노드까지 반복한다.

단계 5: 출력 노드의 값과 목표값의 차이를 구한다.

단계 6: 출력 노드의 값과 목표값의 차이를 이전 퍼셉트론에 전달하여 가중치 값을 수정한다.

단계 7: 수정된 가중치 값을 이용하여 단계 2에서 단계 6까지를 반복한다.

단계 8: 더 이상 학습이 이루어지지 않을 때까지 위의 과정을 반복한다.

다층 퍼셉트론의 학습 단계

- 딥러닝 알고리즘은 여러 퍼셉트론 층을 만든 후 경사하강법의 기울기를 이용하여 각 퍼셉트론 층의 가중치를 점진적으로 수정하는 알고리즘
  - 다양한 수학 기호를 사용하는 이유

1. **명확성**: 수학 표현에서 기호는 특정한 의미를 가지며, 이로 인해 수학적 개념이나 작업을 명확하고 정확하게 표현할 수 있다.
2. **간결성**: 기호를 사용하면 복잡한 개념이나 공식을 간결하게 표현할 수 있다. 예를 들어, 연속적인 덧셈을 나타내는 시그마 기호(∑)나 무한대(∞)와 같은 기호를 사용하면 복잡한 개념을 간단하게 표현할 수 있다.
3. **일반화**: 기호는 특정한 수나 객체 대신 일반적인 개념을 표현하는 데 사용될 수 있다. 이는 공식이나 정리를 일반적인 상황에 적용할 수 있게 해준다.
4. **추상화**: 기호를 사용하면 구체적인 개체나 수치에 얽매이지 않고 더 높은 수준의 추상적인 사고를 가능하게 한다. 이는 복잡한 문제를 해결하는 데 도움이 된다.
5. **의사소통**: 기호는 수학자들 사이의 의사소통을 용이하게 한다. 특정 기호는 전 세계의 수학자들에게 동일한 의미를 가지므로, 이를 통해 수학적 아이디어와 결과를 효과적으로 공유할 수 있다.

다층 퍼셉트론의 학습 단계

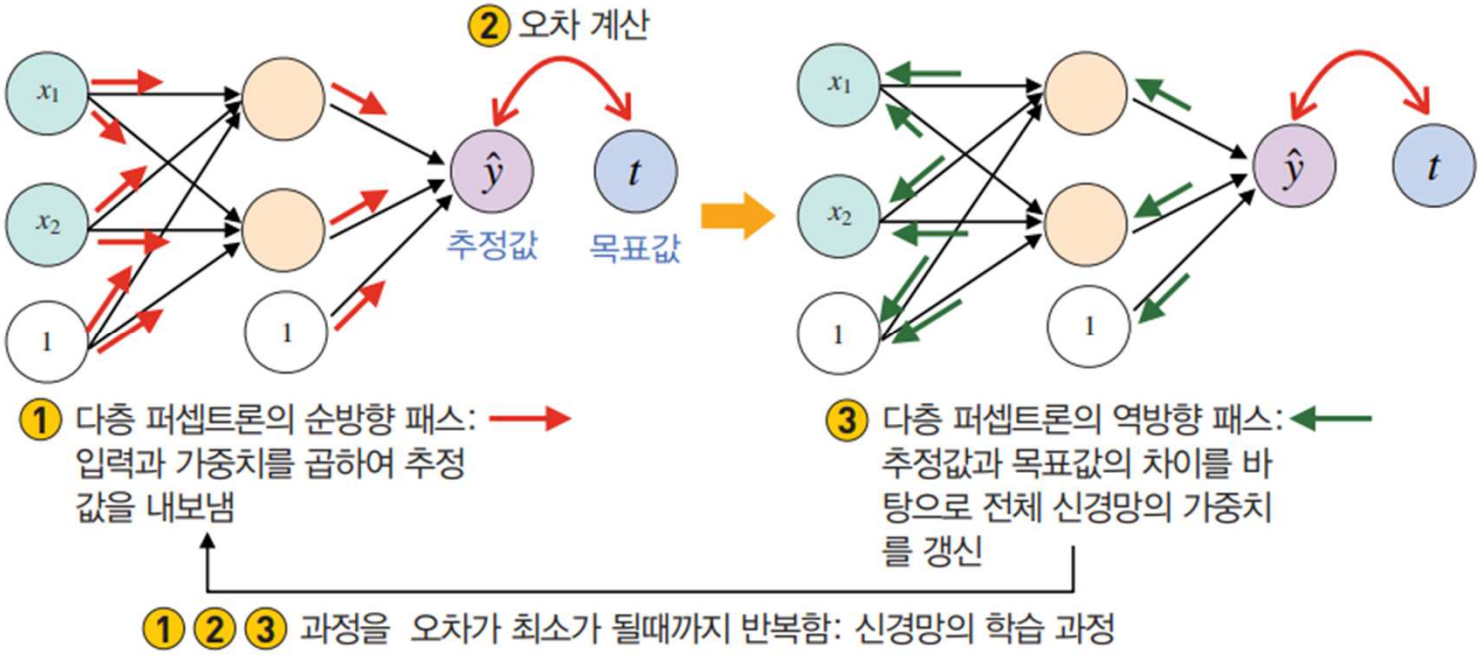
- 이제 심층 신경망의 오차 E에 대해서 가중치 ω를 갱신하는 미분에 대해서 살펴보자. ∂기호는 그리스 문자 δ(델타)의 변형이다.
  - 경사 하강법은 오차와 변수의 기울기를 사용하여 반복적으로 E를 최소화 시키는 방법이다

$$\omega \leftarrow \omega - \eta \cdot \frac{\partial E}{\partial \omega}$$

표기법	의미
E	출력값과 정답값과의 차이인 $(y - t)$로 오차를 의미함
ω	오차가 최소가 되도록 갱신되어야 하는 가중치
$\frac{\partial E}{\partial \omega}$	가중치에 대한 오차의 변화율 (w에 대한 E의 편미분으로 읽는다)
ϕ	활성화 함수
η	가중치를 갱신하기 위한 학습률

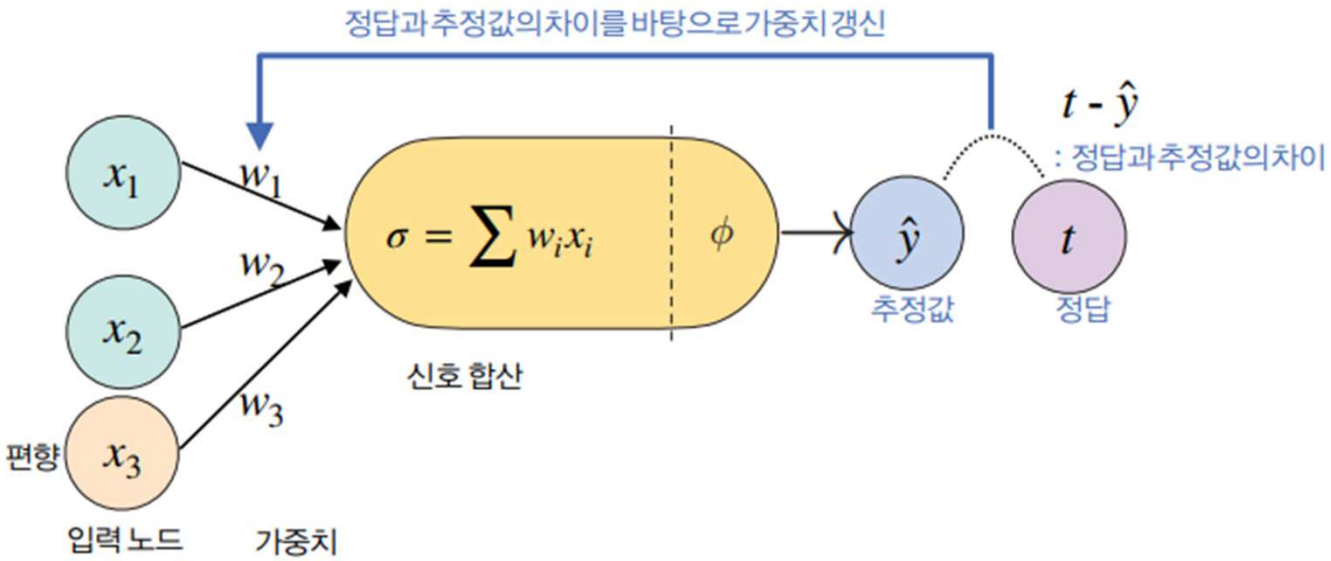
순전파와 역전파

- 1 단계 : 신경망이 연결된 구조에서 신호가 x를 거쳐 y로 전달된다.
  - 이 방향으로 입력값과 가중치 값이 곱해져서 다음 단계로 전달되는 것을 **순전파** forward propagation 라고 한다.
- 2 단계 : 출력 부분에서 확인할 수 있는 목표 t와 출력 $\hat{y}$의 차이가 바로 오차
- 3 단계 : 오차에 대한 미분을 이용하여 연결망을 거꾸로 타고 전달시켜 가중치를 조정하는 단계가 필요하다. 1, 2, 3 단계 과정을 오차가 최소가 되도록 반복 시키자



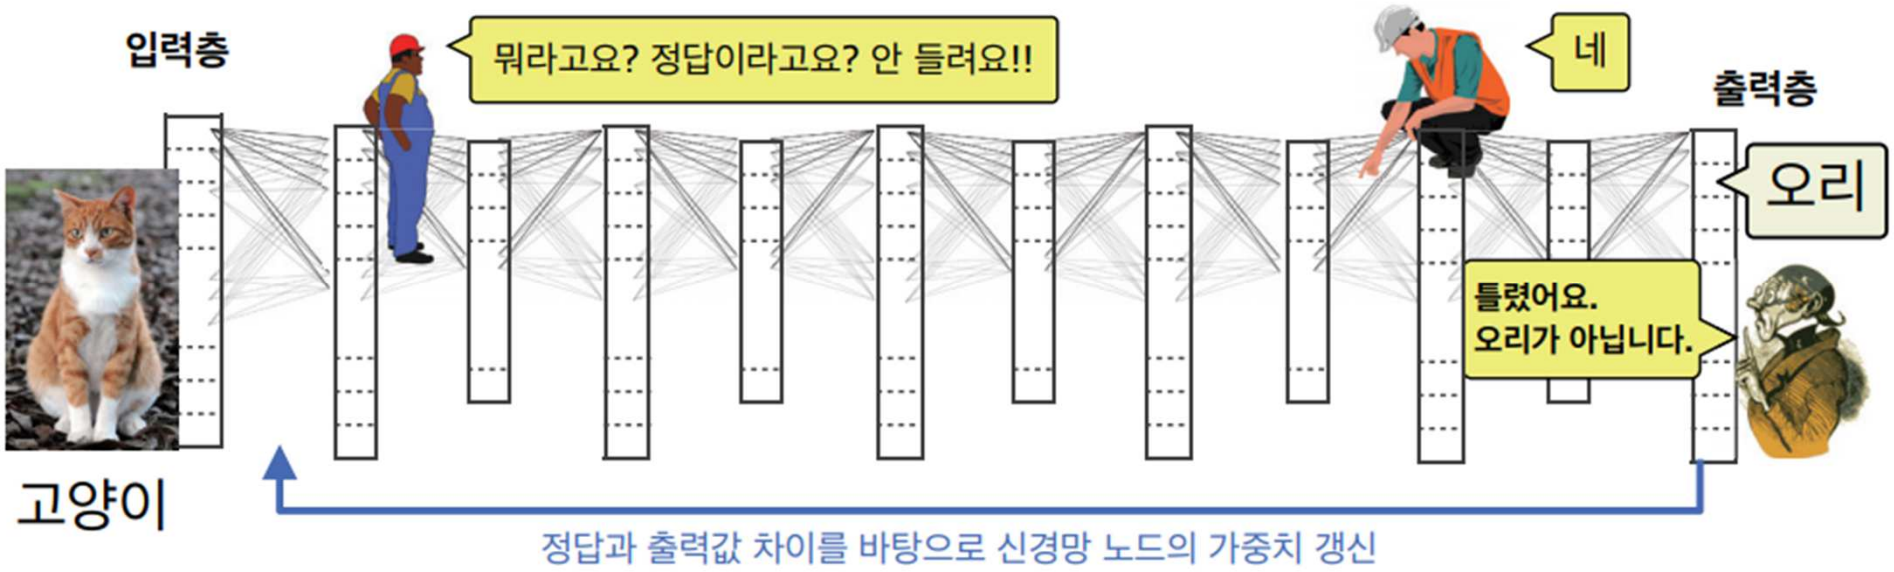
순전파와 역전파

- 역전파 과정이 하나의 층에서 수행될 때
  - 그림과 같이 입력 노드와 가중치, 이들 신호의 합산과 활성화 함수 그리고 추정값과 정답으로 단순화할 수 있다.



순전파와 역전파

- 역전파 단계는 매우 깊은 층을 가지는 모델에 대해서도 효과적으로 잘 수행되어야 하는데, 지난 수십 년 동안 그림과 같이 깊은 층의 신경망이 가지는 많은 가중치를 갱신하는 것은 어려운 일이었다.



오차 역전파 알고리즘의 간략한 역사

- 간략한 역사

1. **1950년대 말:** 오차 역전파의 초기 아이디어는 1950년대 말 프랭크 로젠블랫에 의해 등장했다. 이 방법은 시스템의 출력이 기대하는 결과와 실제 값 사이의 차이를 통해서 입력을 조절하는 방법에 대한 아이디어를 제시했다.
2. **1970년대:** 1970년대에는 연구자들이 다층 퍼셉트론을 학습시키는 방법에 대해 고민하게 된다. 이에 대한 해답으로, 오차 역전파 알고리즘이 제안되었으나 이때에는 큰 주목을 받지 못했다.
3. **1986년:** 오차 역전파 알고리즘은 1986년에 데이비드 럼멜하트, 제프리 힌턴 등이 발표한 논문인 **역방향 오차를 통한 학습 표현**(Learning representations by back-propagating errors)에서 재발견되고 널리 알려지게 되었다. 이 논문에서 제시된 오차 역전파 알고리즘은 다층 퍼셉트론의 학습에 이용되어 실질적으로 신경망 학습이 가능하게 되었다. 그러나 이 알고리즘은 여러 가지 기술적인 문제점을 완전히 극복하지는 못했다.
4. **2006년 이후:** 하지만 2006년에 **제프리 힌턴** 교수의 논문 제목에 등장하는 **심층 신뢰 네트워크** Deep Belief Networks 의 개념과 함께 신경망에 대한 관심이 다시 부상하게 되었다. 이후, 오차 역전파 알고리즘은 빅데이터와 GPU의 발전 그리고 기존의 문제점을 극복한 새로운 신경망 구조의 발명과 함께 현재의 딥러닝 붐의 중심에 서게 되었다.

02 역전파 알고리즘에 대한 직관적 이해

- 계산 그래프를 이용한 오차 역전파의 이해
  - 오차 역전파를 제대로 이해하기 위해서는 수치 미분, 편미분, 선형대수에 대한 지식이 필요하다
  - 이러한 수식 중심의 방법은 많은 수식과 연산이 나오기 때문에 오차 역전파의 본질을 놓칠 수 있다
  - 오차 역전파 문제의 핵심

- **오차 역전파 문제의 핵심:** 오차 역전파 알고리즘은 **신경망의 출력 오차를 거꾸로 전파시켜 각 퍼셉트론의 가중치를 조정하는 방식으로 신경망의 성능을 최적화하는 방법**이다. 이 방법은 딥러닝의 핵심이 되는 알고리즘이다.

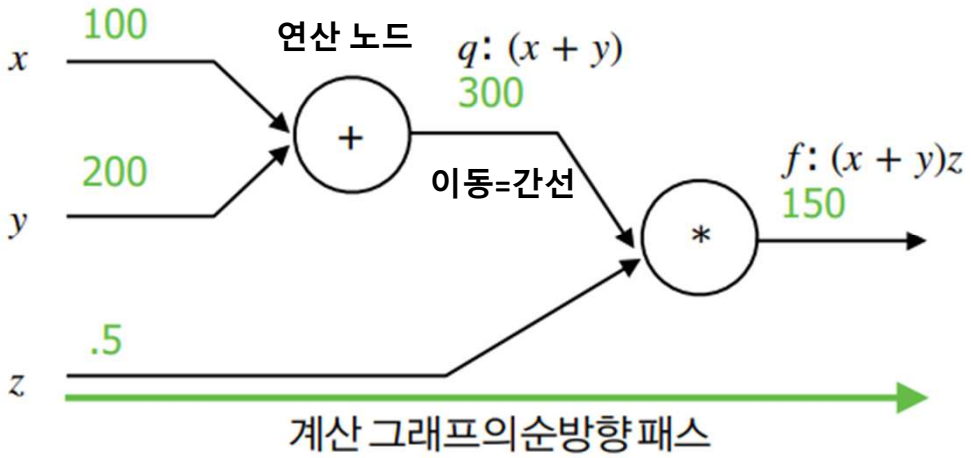
계산 그래프를 이용한 오차 역전파의 이해

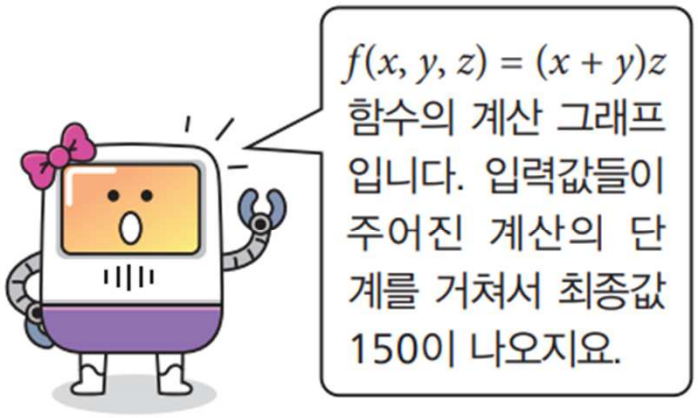
- 계산 그래프란
  - 계산의 과정을 노드와 간선을 가지는 그래프로 나타내는 표현 방법이다.
  - 이 **계산 그래프** computational graph 는 다음과 같은 이유로 오차 역전파 알고리즘을 이해하는 데 유용한 도구이다.

- **시각화:** 계산 그래프는 복잡한 계산 과정을 시각적으로 표현하며, 그래프의 각 노드는 연산을, 간선은 데이터를 나타낸다. 이렇게 하면 연산의 흐름을 쉽게 파악하고, 미분을 적용할 때 어떤 식으로 진행되는지 이해하는 데 도움이 된다.
- **연쇄 법칙의 적용:** 여러 계산 단계의 그래프상에서 미분 계산을 할 때 연쇄 법칙을 이용하는데, 계산 그래프는 이 연쇄 법칙이 어떻게 적용되는지 직관적으로 이해하는 데 도움이 된다. 또한 그 과정을 시각적으로 나타내어 주므로 유용하다. 오차 역전파 계산 과정에서는 각 노드에서의 지역 기울기값을 미리 계산한 후, 이들을 역방향으로 곱하여 최종 미분값을 얻는데, 계산 그래프는 이 과정을 명확하게 보여준다.
- **효율성:** 계산 그래프를 사용하면, 순방향 계산과 역방향 계산을 모두 수행할 수 있다. 이는 중간 계산 결과를 재사용하므로, 계산량을 줄이고 효율성을 높이는 데 도움이 된다.

계산 그래프의 순방향 계산

- 순방향 계산을 알아보자
  - 함수 : $f(x, y, z) = (x + y)z$
  - 이 함수에 대한 계산 그래프
    - 함수에 x, y, z 값으로 100과 200, 0.5를 준다면 어떻게 될까?
    - 다음과 같이 **연산을 의미**하는 **노드**node와 **이동을 의미**하는 **간선**edge의 형태를 가지는 구조, 그리고 이들의 흐름이 계산 단계가 된다





계산 그래프의 순방향 계산

- 계산 그래프의 순방향 패스
  - q라는 임시 변수 도입으로 해결하자

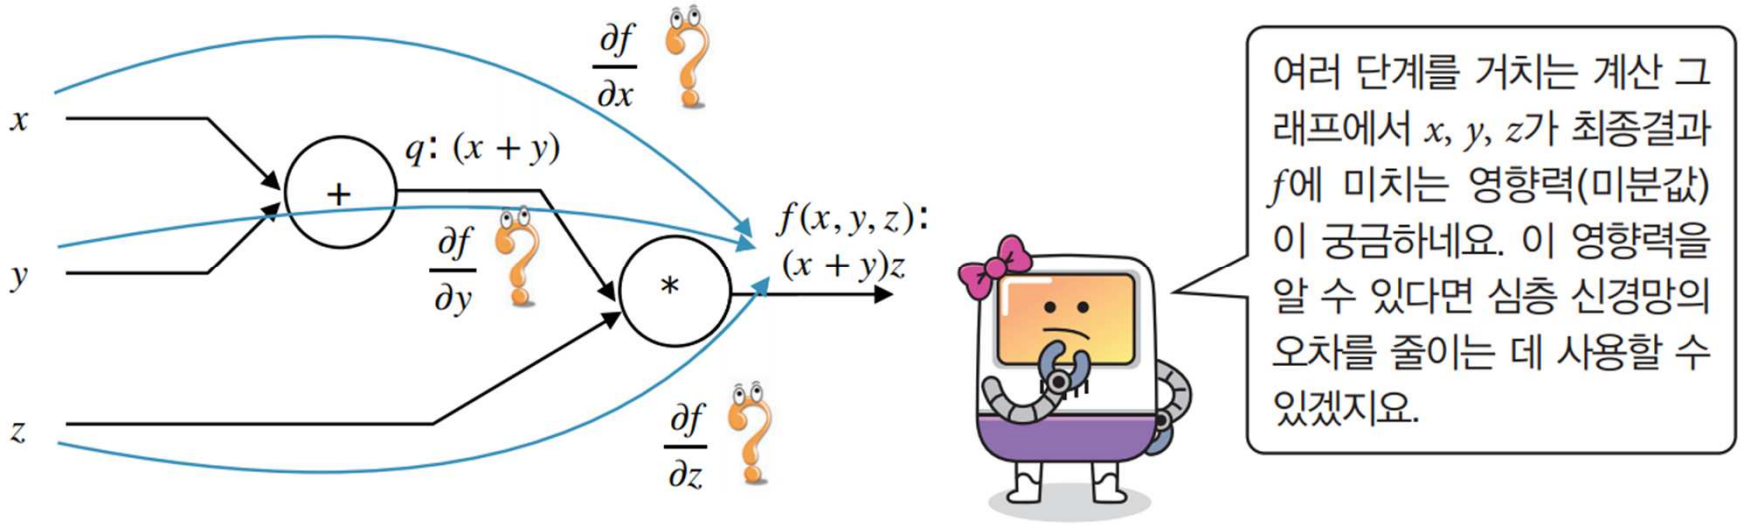
```
# x, y, z 입력값 지정하기
x, y, z = 100, 200, 0.5
print('x =', x, 'y =', y, 'z =', z)

# 순방향 패스를 계산하자
q = x + y       # 임시 변수 q는 300을 가짐
f = q * z       # f는 150
print('순방향 패스의 결과 : q =', q, 'f =', f)
```

```
x = 100 y = 200 z = 0.5
순방향 패스의 결과 : q = 300 f = 150.0
```

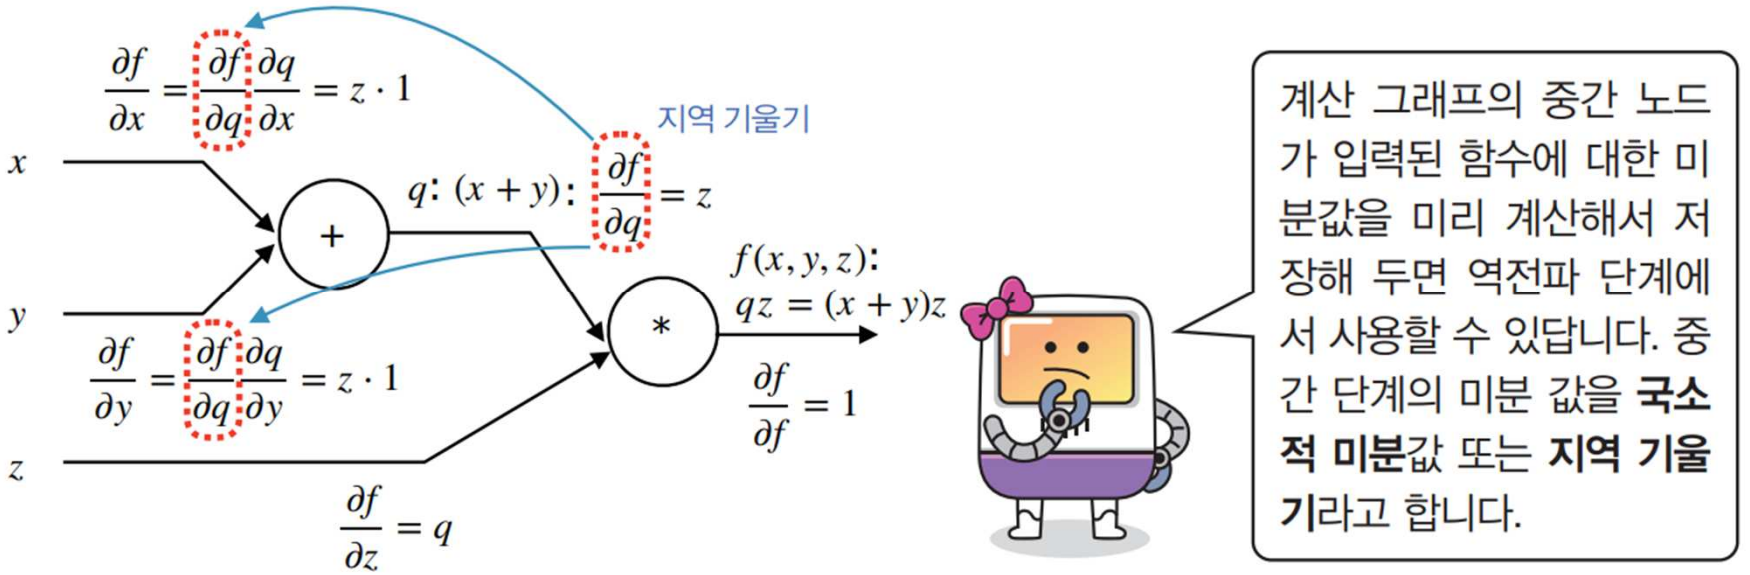
계산 그래프의 순방향 계산

- 위의 식에서 q = (x + y)이고 f = qz이므로 이러한 단계를 밟아서 최종적으로 f 값이 계산되었는데, 역전파 단계는 이 과정을 거꾸로 올라가는 방식을 사용하게 된다.
  - 역전파를 사용하는 이유는 그림과 같이 입력값 x, y, z가 최종 결과 f에 미치는 영향력을 알아보고 이 영향력만큼 가중치를 조정하여 최종 출력 오차를 줄이기 위해서이다



계산 그래프의 순방향 계산

- x, y, z가 최종 결과 f에 미치는 영향력을 미분 표현식으로 나타내면 $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$로 나타낼 수 있다.
  - x에 대한 f의 편미분 $\frac{\partial f}{\partial x}$은 직접적으로 구할 수 없다.
  - 연쇄법칙을 사용하면 가능하다. $\frac{\partial f}{\partial q}\frac{\partial q}{\partial x}$를 통해서 알 수 있다



계산 그래프의 순방향 계산

- q에 대한 f의 변화량 $\frac{\partial f}{\partial q}$, x에 대한 q의 변화량 $\frac{\partial q}{\partial x}$을 구한 다음, 이를 이용하면 $\frac{\partial f}{\partial x}$를 구할 수 있다.
- y에 대한 f의 편미분 $\frac{\partial f}{\partial y}$ 역시 이 방식으로 구할 수 있다.
  - 편미분값은 계산 그래프의 중간 노드가 입력된 함수에 대한 미분값을 미리 계산해서 저장하면 역전파 단계에서 사용할 수 있다.
  - 이와 같이 중간 노드가 가진 중간 단계의 미분 값을 **국소적 미분값** 또는 **지역 기울기** 라한다.
  - q = (x +y)로 부터 얻을 수 있는 지역 기울기 : $\frac{\partial q}{\partial x} = 1, \quad \frac{\partial q}{\partial y} = 1$
  - f = qz로 부터 얻을 수 있는 편미분값 : $\frac{\partial f}{\partial q} = z, \quad \frac{\partial f}{\partial z} = q$

계산 그래프의 순방향 계산

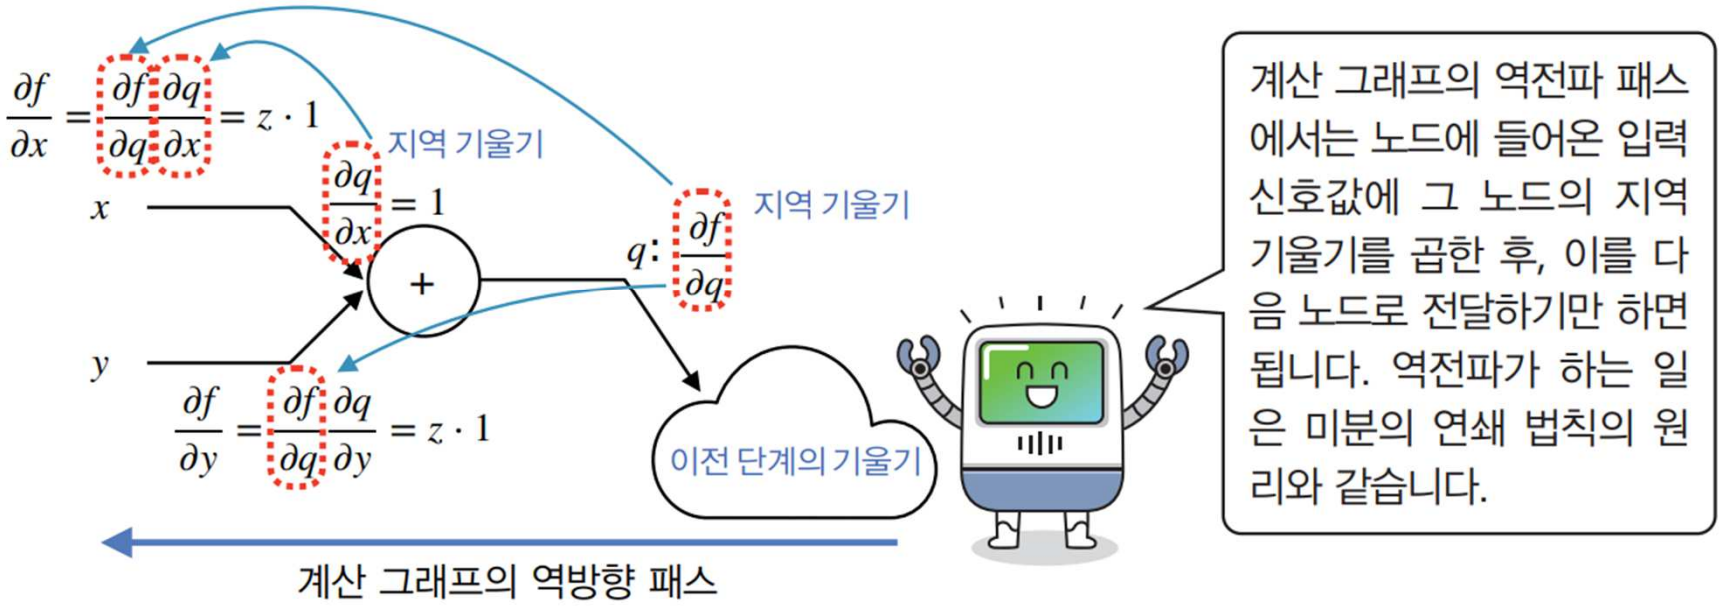
$$\frac{\partial q}{\partial x} = 1, \quad \frac{\partial q}{\partial y} = 1 \qquad \frac{\partial f}{\partial q} = z, \quad \frac{\partial f}{\partial z} = q$$

- x에 대한 f의 변화량 $\frac{\partial f}{\partial x}$, y에 대한 f의 변화량 $\frac{\partial f}{\partial y}$을 구해보자

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial q}\frac{\partial q}{\partial x} = z \cdot 1 = z, \quad \frac{\partial f}{\partial y} = \frac{\partial f}{\partial q}\frac{\partial q}{\partial y} = z \cdot 1 = z$$

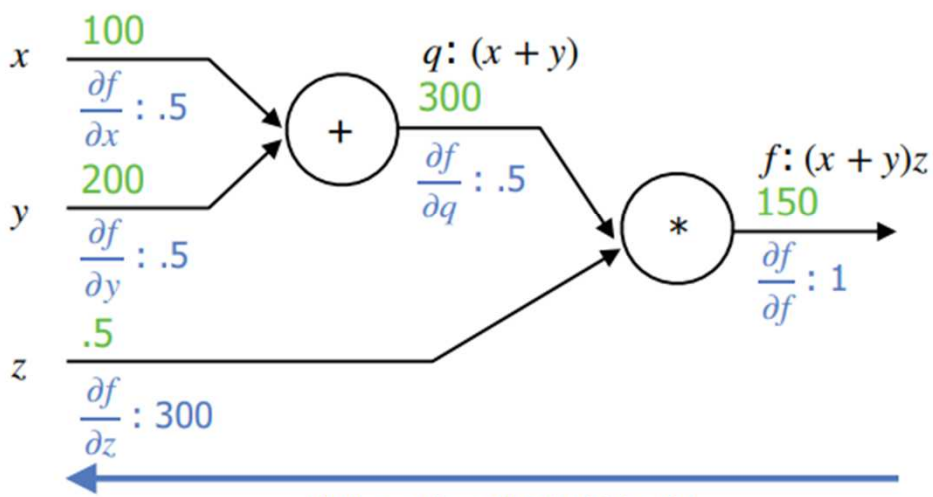
계산 그래프의 순방향 계산

- 연쇄법칙의 원리를 이용하여 x에 대한 f의 기울기, y에 대한 f의 기울기 그리고 z에 대한 f의 기울기 $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$를 구할 수 있다.
  - 순방향 계산 단계에서 지역 기울기만 구할 수 있다면 매우 깊은 층에 대해서도 이 원리는 적용가능하다

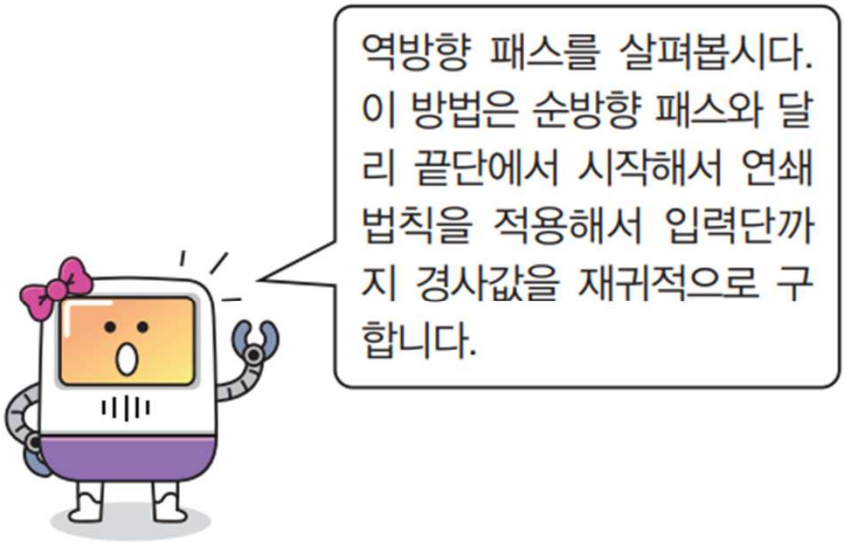


계산 그래프의 역방향 계산

- 역방향 패스는 그림에서 파란색으로 표시되어 있다.
  - 이 방법은 순방향 패스와 달리 출력 노드에서 시작해서 연쇄 법칙을 적용하여 입력 노드까지 경사값을 재귀적으로 구하게 된다.
  - 역방향 단계에서 가장 먼저 계산하는 것은 $\frac{\partial f}{\partial f}$인데 이 값은 자명하게 1이 된다
  - 다음으로 $\frac{\partial f}{\partial q}$를 계산하면 이 값은 앞에서 구한 것과 같이 z가 된다
    - 따라서 실제값은 .5가 됨(입력값 z는 .5임)



계산 그래프의 역방향 패스

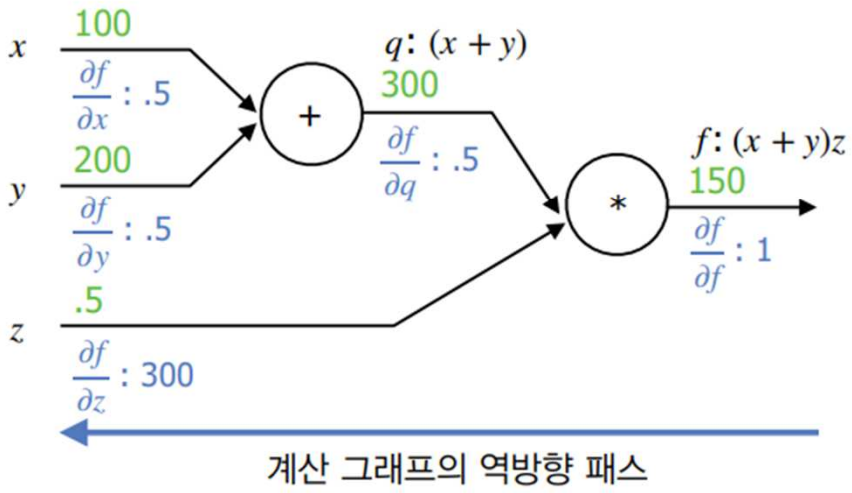


계산 그래프의 역방향 계산

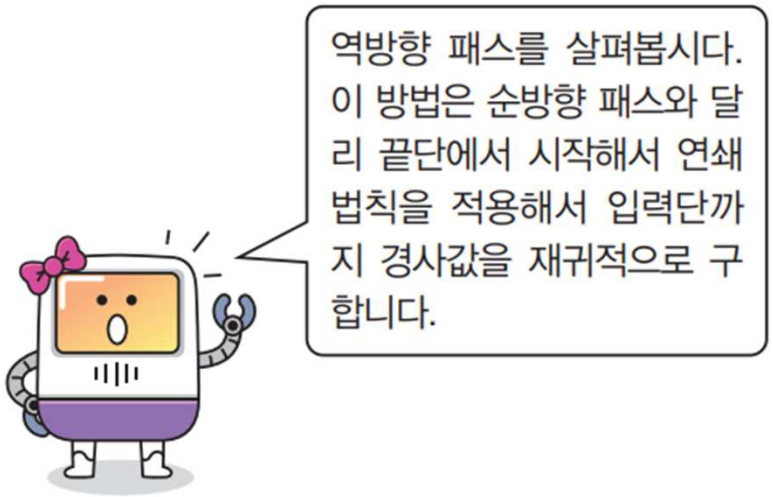
- 다음으로 $\frac{\partial f}{\partial z}$를 계산하면 이 값은 q와 같다.(q값은 300이다)

- 마지막 단계로 $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}$를 구하면 모두 z가 됨(z값은 .5이다)

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial q}\frac{\partial q}{\partial x} = z \cdot 1 = z, \quad \frac{\partial f}{\partial y} = \frac{\partial f}{\partial q}\frac{\partial q}{\partial y} = z \cdot 1 = z$$



계산 그래프의 역방향 패스



계산 그래프의 역방향 계산

- 코드

```
# 역방향 패스를 역순으로 수행하자
# 최초 역전파는 f = q * z부터 시작함
dfdz = q                # df/dz = q, 따라서 z의 기울기는 300
dfdq = z                # df/dq = z, 따라서 q의 기울기는 .5
dqdx = 1.0
dqdy = 1.0
# q = x + y를 역전파시켜보자
dfdx = dfdq * dqdx  # 연쇄 법칙에 의한 값
dfdy = dfdq * dqdy

print('df/dx = ', dfdx)
print('df/dy = ', dfdy)
print('df/dz = ', dfdz)
```

```
df/dx =  0.5
df/dy =  0.5
df/dz =  300
```

계산 그래프의 역방향 계산

NOTE: 오차 역전파에 대한 직관적인 이해



딥러닝의 가장 핵심적인 학습 원리인 역전파는 사실 매우 **국소적인 과정**이다. 계산 그래프의 모든 노드는 이웃 노드로부터 입력을 받아서 두 가지의 일을 한다. 하나는 순방향 전파를 위한 출력값을 계산하는 것이며, 다른 하나는 입력에 대한 출력의 지역 기울기를 구하는 것이다. 이때 **지역 노드는 전체 계산 그래프의 세부적인 정보를 모두 다 인식하지 않더라도 완전히 독립적으로 이 작업을 수행할 수 있다.**

일단 순방향 패스가 종료되고 나서 이루어지는 오차 역전파 과정에서 계산 그래프의 각 노드는 전체 그래프의 최종 출력에 대한 영향력을 얻기 위하여 순전파 단계에서 구한 지역 기울기를 이용한다. 미분의 중요한 개념인 연쇄 법칙을 잘 이용하면, 각 노드는 지역 기울기를 사용하여 모든 입력값이 출력에 미치는 영향력을 알 수 있다.

- 다음 도전 문제를 풀어보자

도전 문제 6.1: 계산 그래프 만들기

상 중 하



1. 다음과 같은 형태의 수식 $f(x)$가 있다. 이 수식을 계산 그래프로 나타내어라.

$$f(x) = x(y + z)$$

2. 동윤이는 동네 편의점에서 김밥을 두 개, 보리음료를 네 개 구입했다. 김밥은 3,000원, 보리음료는 1,200원이다. 이 물건들은 모두 원래 가격에 10%의 부가가치세를 내고 구입해야만 한다. 동윤이가 구입한 물건들과 개수를 이용하여 동윤이가 최종적으로 지불한 돈을 계산 그래프로 나타내고 계산하여라.

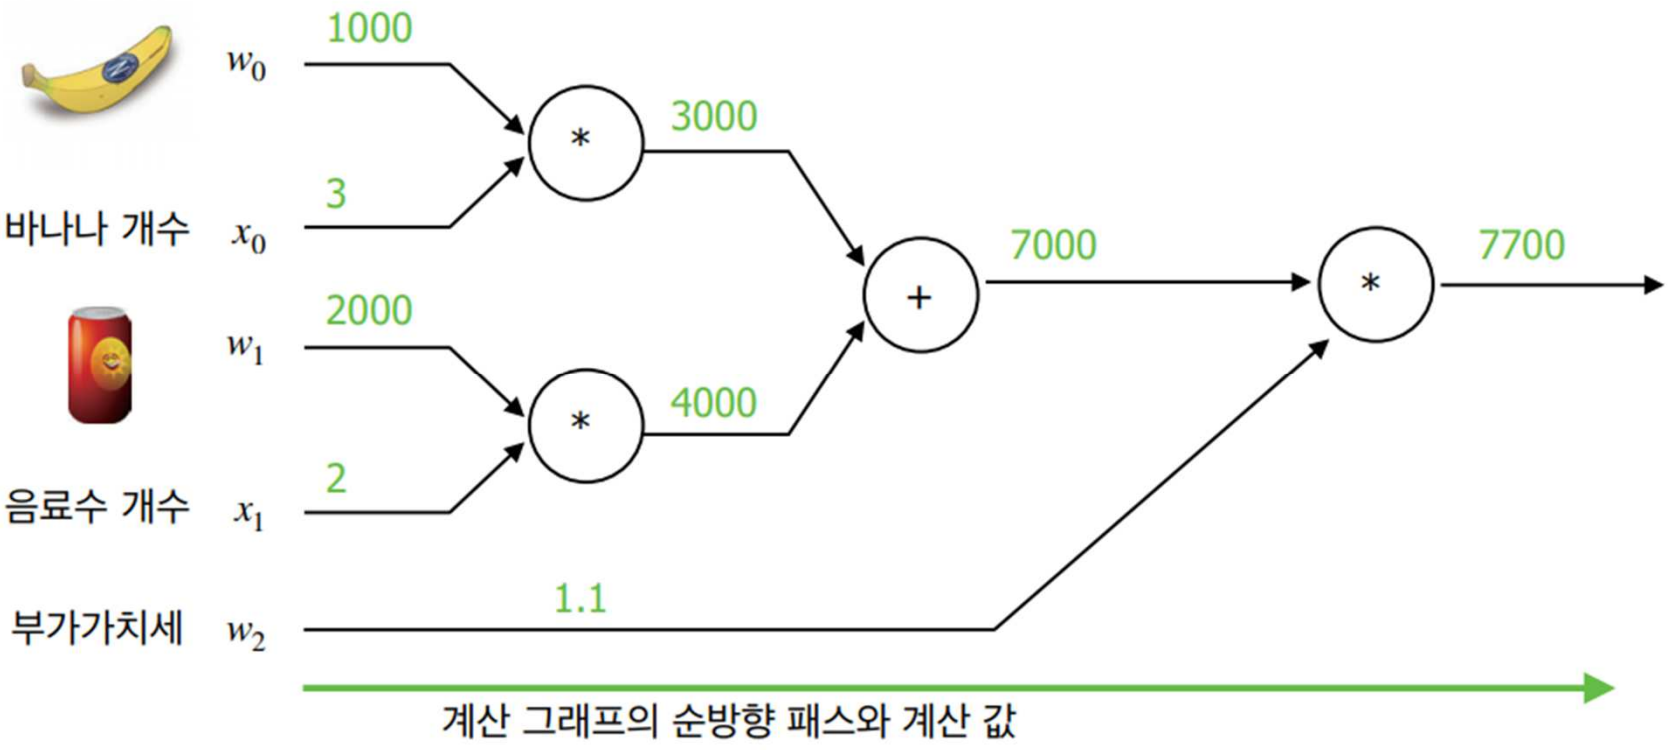
03 계산 그래프 실습하기

- 도전 문제 6.1의 두 번째 문제를 다시 한번 살펴보자.
  - 이 문제는 다음과 같이 수정할 수 있다.

동윤이는 동네 편의점에서 바나나를 세 개, 음료수를 두 개 구입했다. 바나나는 1,000원, 음료수는 2,000원이다. 이 물건들은 모두 원래 가격에 10%의 부가가치세를 내고 구입해야만 한다. 동윤이가 구입한 물건들과 개수를 이용하여, 동윤이가 최종적으로 지불한 돈을 계산 그래프로 나타내고 그 결과를 계산하여라. 계산 그래프에서 최종적으로 지불한 돈에 대한 순방향 패스값을 구하여라.

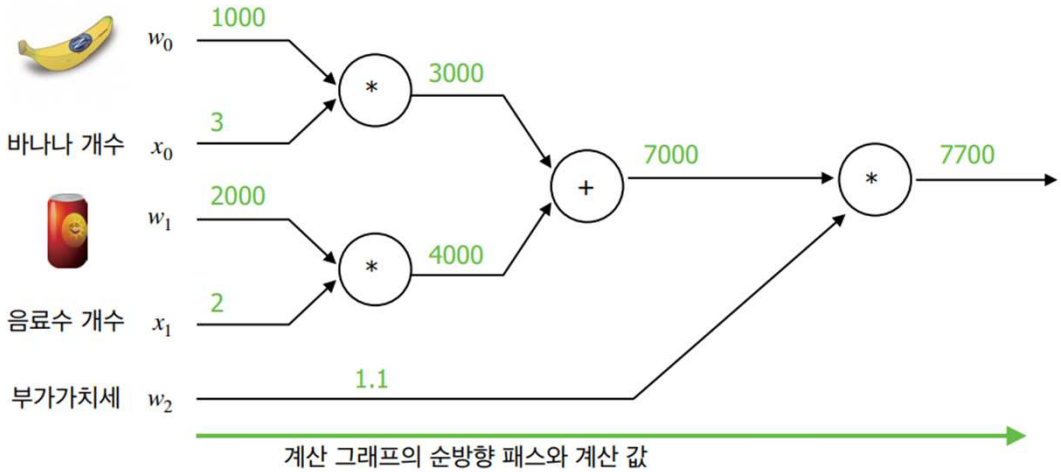
03 계산 그래프 실습하기

- 동윤이가 지불한 돈을 계산 그래프로 구해보도록 하자.
  - 동윤이는 바나나 세 개와 음료수 두 개를 구입했고 각각의 가격이 1,000원, 2,000원 이므로 다음과 같이 계산 그래프로 표현할 수 있다.
  - 각각은 다음과 같은 수학적 표기와 계산 그래프로 나타냄



03 계산 그래프 실습하기

- 그림의 계산이 이루어지는 과정



- 바나나 한 개 가격: 1,000원, 개수: 세 개로 전체 금액은 3,000원
- 음료수 한 개 가격: 2,000원, 개수: 두 개로 전체 금액은 4,000원
- 바나나 세 개, 음료수 두 개의 전체 가격은 3,000원 + 4,000원 = 7,000원
- 7,000원에 대한 부가세 10%: 700원
- 최종적으로 지불한 돈 7,700원

- 계산 그래프를 f(x, ω)라는 이름의 함수로 표현
  - 함수의 변수는 ω_0, x_0, ω_1, x_1,ω_2이므로 간략하게 f(x, ω)로 표기하였다.

$$
\begin{aligned}
f(x, \omega) &= (\omega_0 x_0 + \omega_1 x_1)\omega_2 \\
&= (1000 \times 3 + 2000 \times 2) \times 1.1 \\
&= 7700
\end{aligned}
$$

- 계산 그래프의 특징을 자세히 살펴보면 계산 과정에서 사용된 연산 노드는 곱셈 노드와 덧셈 노드만 있다는 것을 알 수 있다.
  - 퍼셉트론 연산에서 활성화 함수를 제외하면 대부분의 연산은 곱셈과 덧셈이다
  - 이제 곱셈 노드와 덧셈 노드가 역전파 단계에서 어떤 일을 하는지 먼저 살펴보도록 하자.

곱셈 노드, 덧셈 노드의 미분과 역전파 과정

- 곱셈 노드의 미분과 역전파 과정
  - 곱셈 노드의 계산 그래프를 구하기 위해서 다음과 같이 p_0, p_1, q라는 임시 변수를 정의하자.

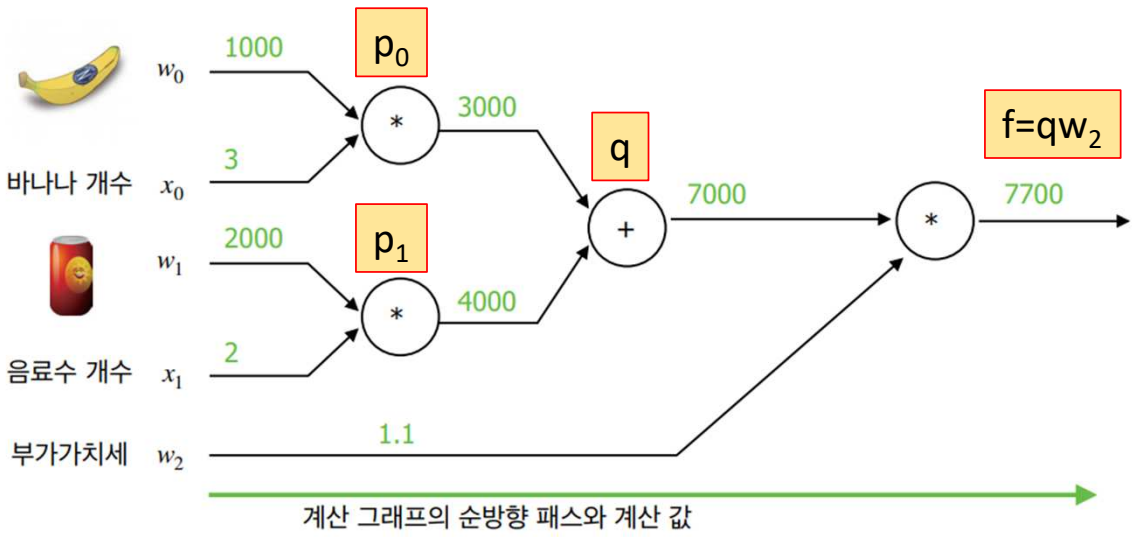
$$p_0 = \omega_0 x_0$$

$$p_1 = \omega_1 x_1$$

$$q = p_0 + p_1$$

  - 출력 함수 f는 다음과 같이 정의 됨

$$f = q\omega_2$$



곱셈 노드, 덧셈 노드의 미분과 역전파 과정

- 함수 f를 q와 ω_2에 대하여 각각 편미분을 하면 어떻게 될까?
  - 계산 그래프의 함수 f가 두 변수의 곱으로만 이루어진 경우 그리고 이 변수들이 모두 차수가 1인 변수인 경우에 대해서만 고려해 보자.
  - 이 경우, 각 변수에 대하여 함수 f를 편미분하면 그 결과는 차수가 1인 변수가 사라지고 다른 변수만 남는다

$$f = q\omega_2 \Rightarrow \frac{\partial f}{\partial q} = \omega_2, \quad \frac{\partial f}{\partial \omega_2} = q$$

  - 이 결과는 매우 단순하기 때문에 우리는 계산 그래프의 순방향 계산 과정에서 이 결과값을 미리 계산해 둘 수 있을 것이다
  - p_0와 p_1에 대해서도 다음과 같은 편미분 결과를 얻을 수 있다

$$p_0 = \omega_0 x_0 \Rightarrow \frac{\partial p_0}{\partial \omega_0} = x_0, \quad \frac{\partial p_0}{\partial x_0} = \omega_0$$

$$p_1 = \omega_1 x_1 \Rightarrow \frac{\partial p_1}{\partial \omega_1} = x_1, \quad \frac{\partial p_1}{\partial x_1} = \omega_1$$

곱셈 노드, 덧셈 노드의 미분과 역전파 과정

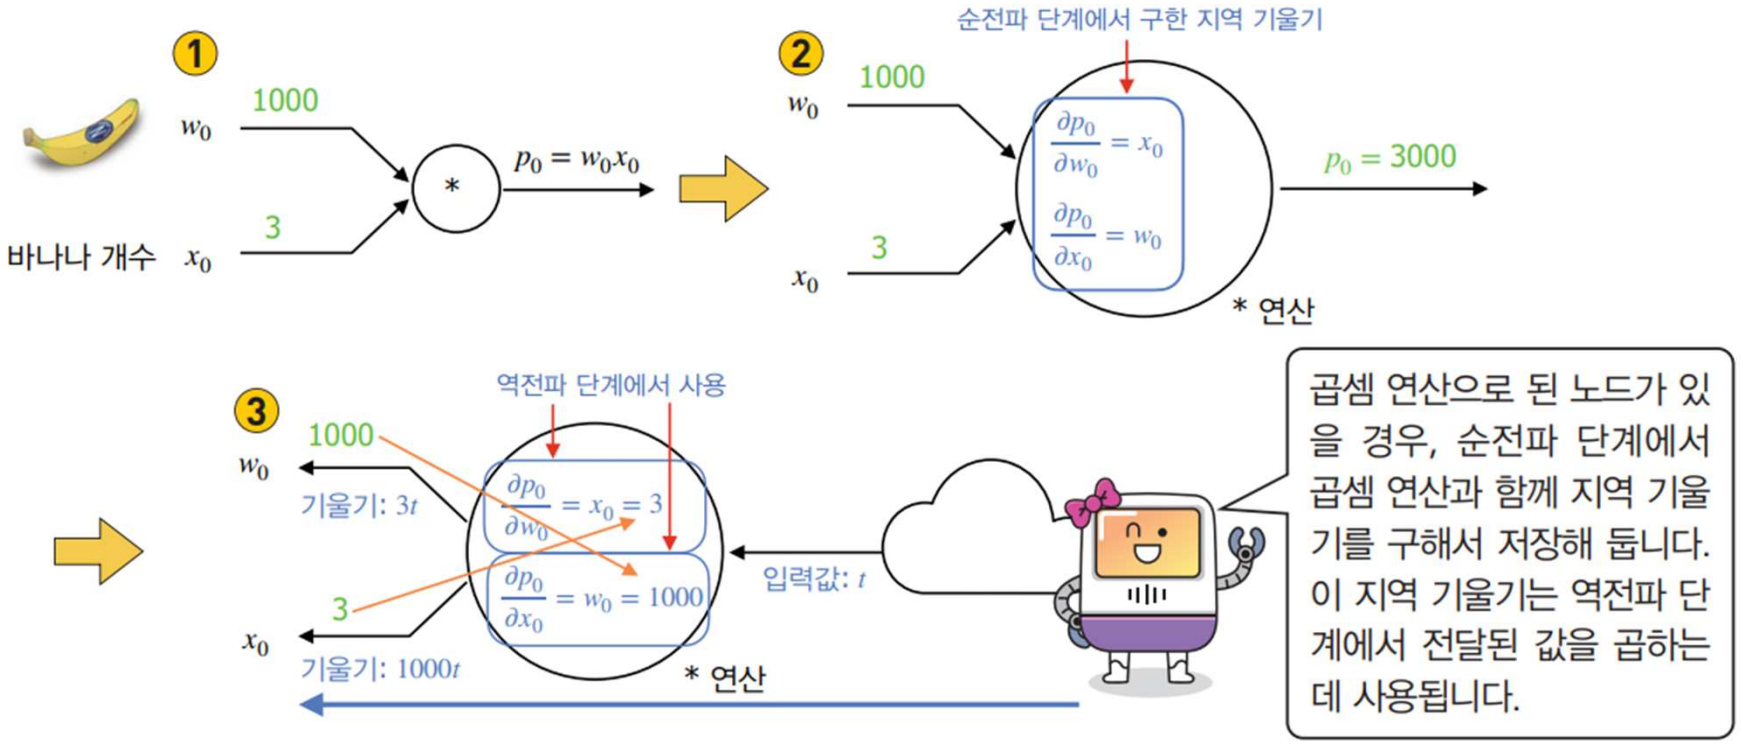
- 우리는 다음과 같은 특징을 살펴볼 수 있다.

두 변수의 단순 곱셈으로 이루어진 함수 $f(x, y) = xy$가 있을 경우, 이 함수의 x에 대한 편미분 $\frac{\partial f}{\partial x}$는 y이며,

$\frac{\partial f}{\partial y}$는 x이다.

곱셈 노드, 덧셈 노드의 미분과 역전파 과정

- 이 특징을 바탕으로 계산 그래프의 순방향 전파 단계에서 다음 그림과 같
- 이 지역 기울기를 구할 수 있다.
  - 즉, 단순 곱셈 노드에서 지역 기울기는 다른 노드에서 입력된 변수값을 그대로 사용하면 되는 것이다



곱셈 노드, 덧셈 노드의 미분과 역전파 과정

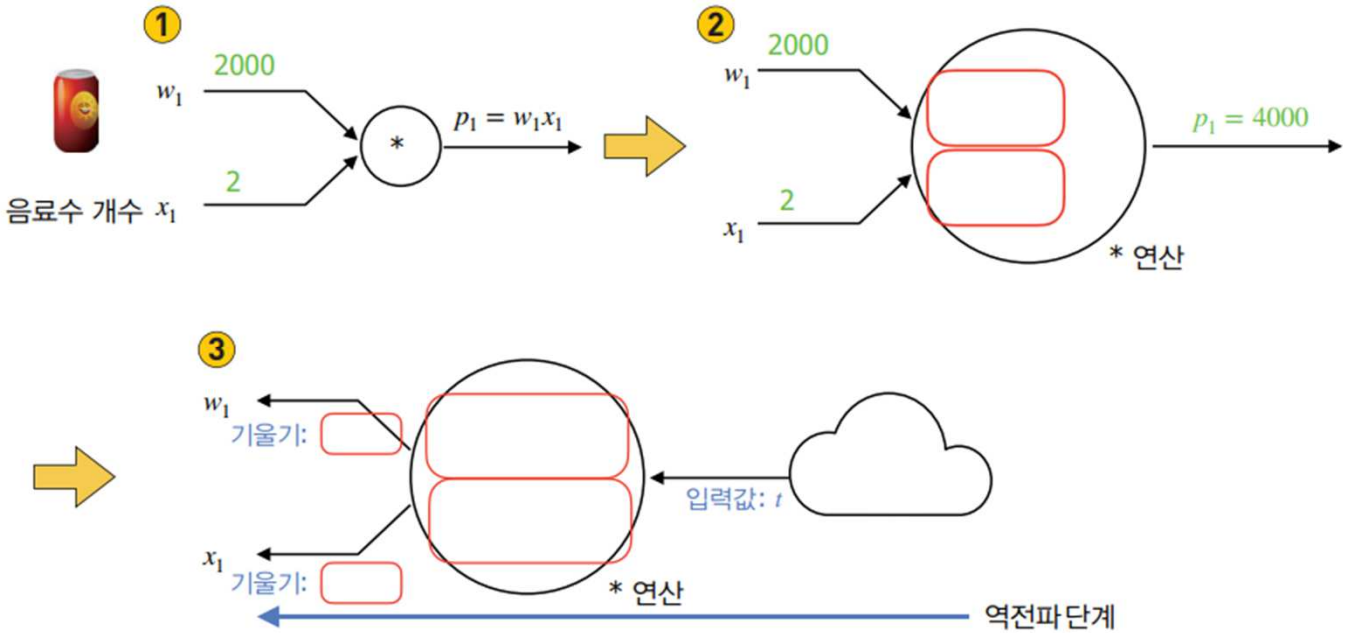
- 다음 도전 문제를 풀어보자

도전 문제 6.2: 역전파 단계의 입력과 기울기

상 중 하



다음은 2,000원짜리 음료수와 이 음료수를 두 개 구입한 상황의 계산 그래프이다. 이 계산 그래프에서 빨간색 사각형 영역에 들어갈 알맞은 수식을 넣어 보도록 하자. 그림의 ①, ②, ③은 모두 이 절에서 설명한 내용과 같이 순전파와 역전파 단계를 나타낸다.



곱셈 노드, 덧셈 노드의 미분과 역전파 과정

- 덧셈 연산의 미분과 계산 그래프 그리고 역전파 과정에 대하여 살펴보자.
  - 다음 q에 대하여 p_0, p_1에 대한 편미분 결과는?

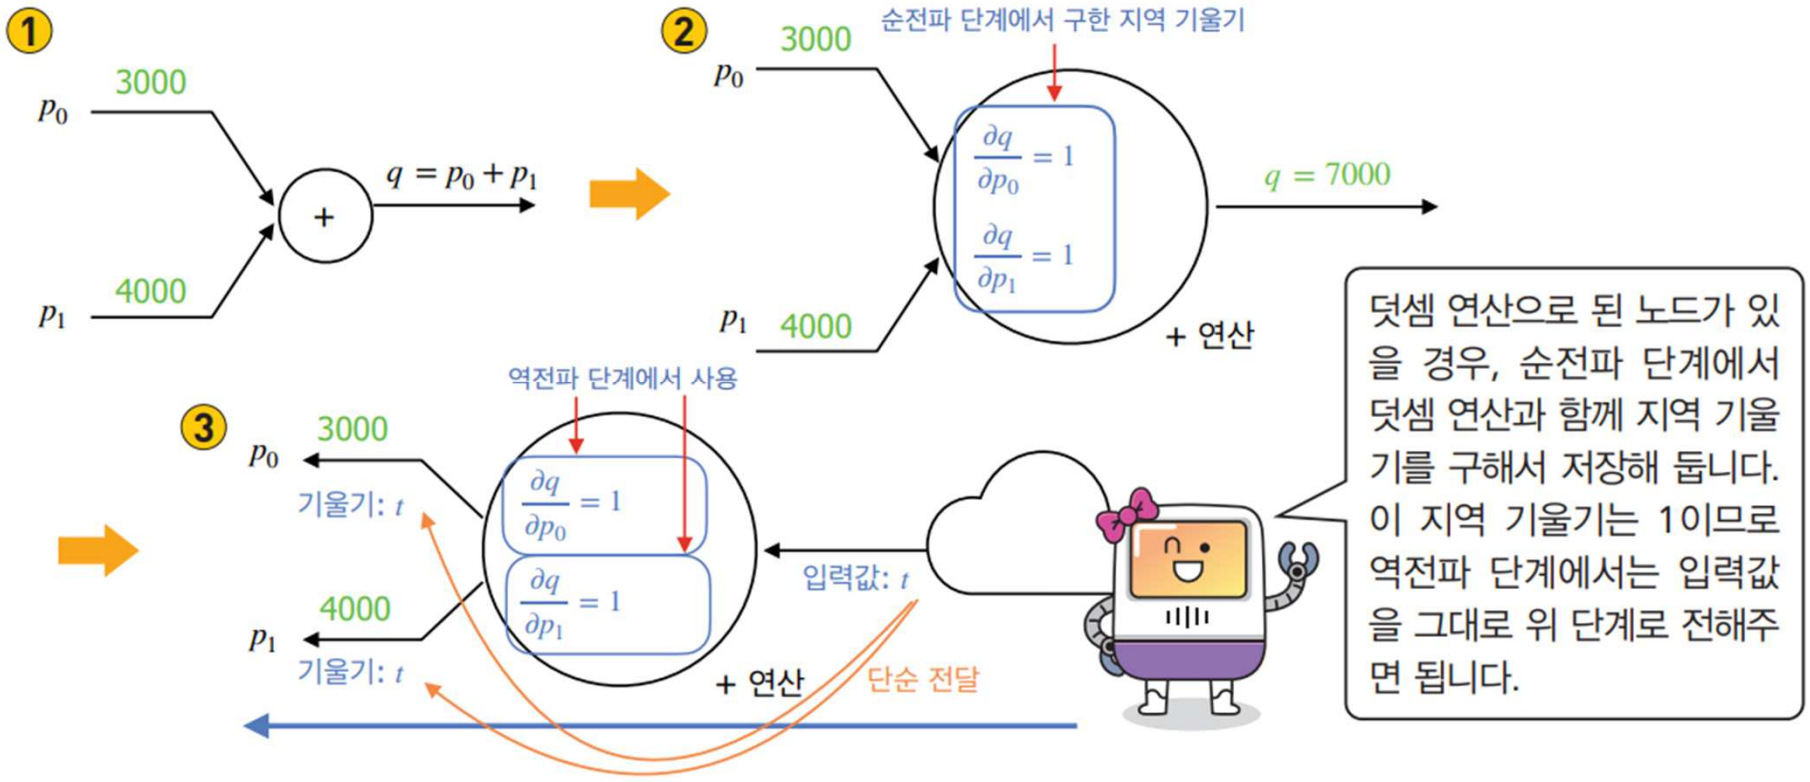
$$q = p_0 + p_1 \Rightarrow \frac{\partial q}{\partial p_0} = 1, \quad \frac{\partial q}{\partial p_1} = 1$$

  - 편미분 결과는 위와 같이 1이므로 계산 그래프는 이 값을 지역 기울기값으로 저장하면 된다.
  - 두 변수의 단순한 곱으로 된 함수의 편미분과는 달리 덧셈 연산의 편미분은 다음과 같은 특징을 가진다.

> 두 변수의 단순 덧셈으로 이루어진 함수 $f(x, y) = x + y$가 있을 경우 이 함수의 x에 대한 편미분 $\frac{\partial f}{\partial x}$는 1이며,
>
> $\frac{\partial f}{\partial y}$도 역시 1이다.

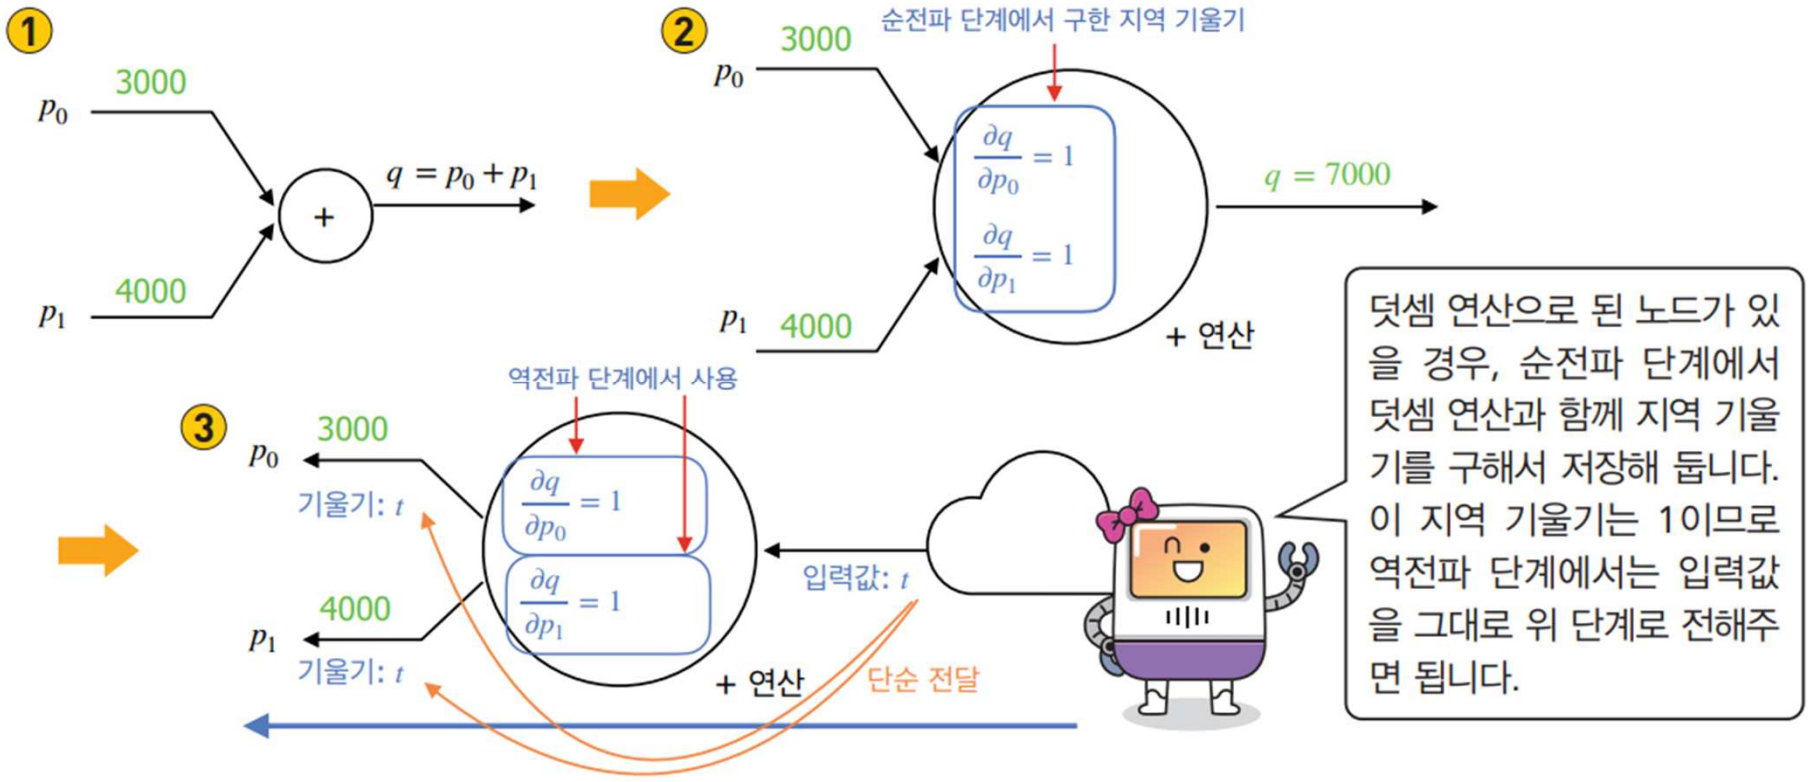
곱셈 노드, 덧셈 노드의 미분과 역전파 과정

- 차수가 1인 변수들의 단순 덧셈 연산 편미분값은 1이 된다
  - 편미분의 결과로 나타난 1 값은 순전파 단계에서 미리 계산되어 저장된다(그림 1 , 2). 그리고 이 값은 그림 3 과 같이 역전파 단계에서 사용된다.



곱셈 노드, 덧셈 노드의 미분과 역전파 과정

- 앞서 살펴본 곱셈 노드와 마찬가지로 여러 단계를 거친 t라는 입력에 대해서 역전파 단계인 3 에서는 p0 방향의 기울기와 p1 방향의 기울기 모두에 대하여 t를 단순히 전달하기만 한다.



전체 계산 그래프를 만들기

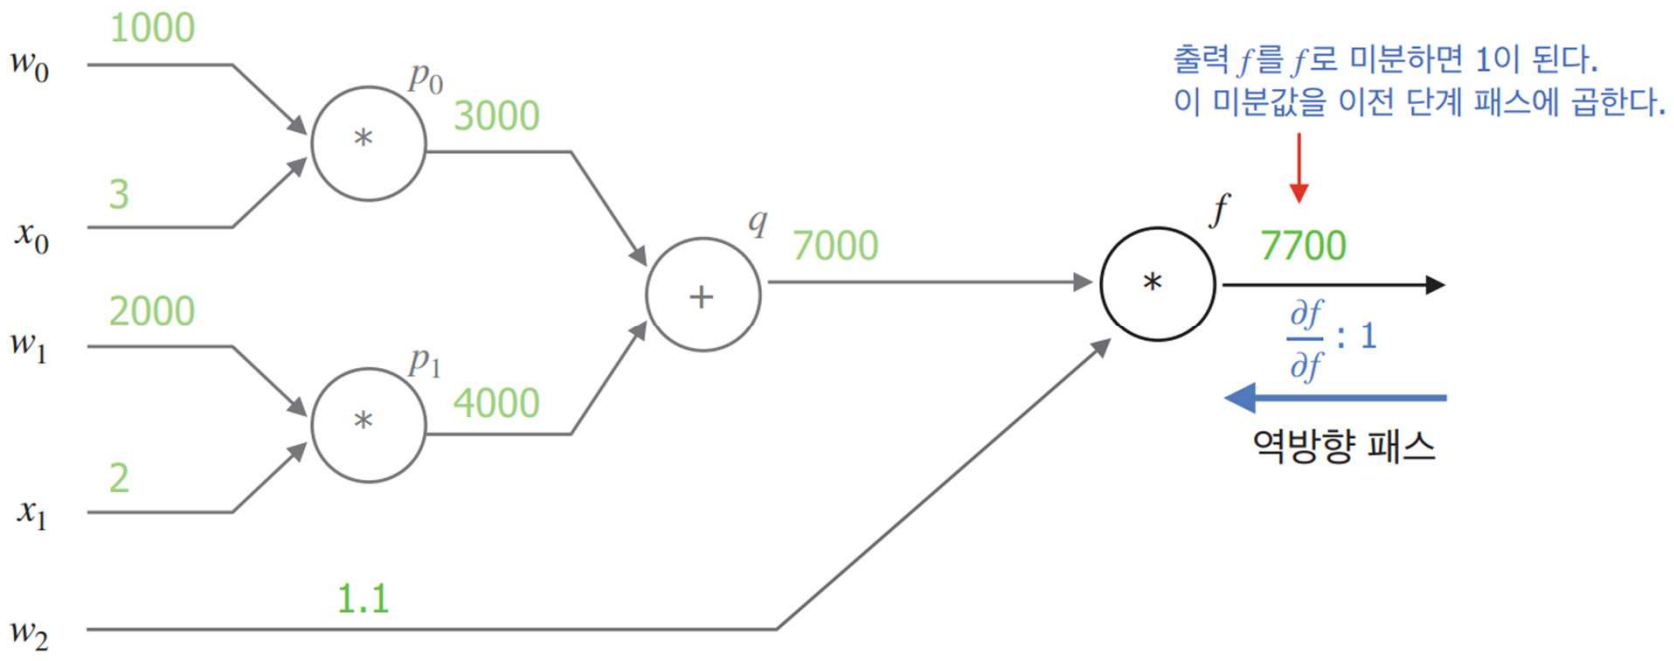
- 계산 그래프 연산과 각 노드에 대한 편미분 결과를 바탕으로 다음과 같은 규칙을 만들고 이 규칙에 따라서 역전파를 수행하도록 하자.
  - 다음은 계산 그래프의 수식이 **덧셈과 곱셈으로만 이루어진 간단한 경우**에 대한 수행 규칙이다

단순 노드들의 역전파 수행 규칙

- **규칙 1:** 최종 노드의 미분은 자기 자신에 대한 미분이므로 1이 된다.
- **규칙 2:** 두 노드의 곱으로 이루어진 노드를 만나면 두 입력의 값을 서로 바꾼 값을 곱해서 다음 노드에 전달한다. 이 과정은 두 입력값의 교환 전달과 같다.
- **규칙 3:** 두 노드의 덧셈으로 이루어진 노드를 만나면 입력값을 다음 노드에 단순히 전달하기만 한다. 이 과정은 두 입력값을 통과시키는 것과 같다.

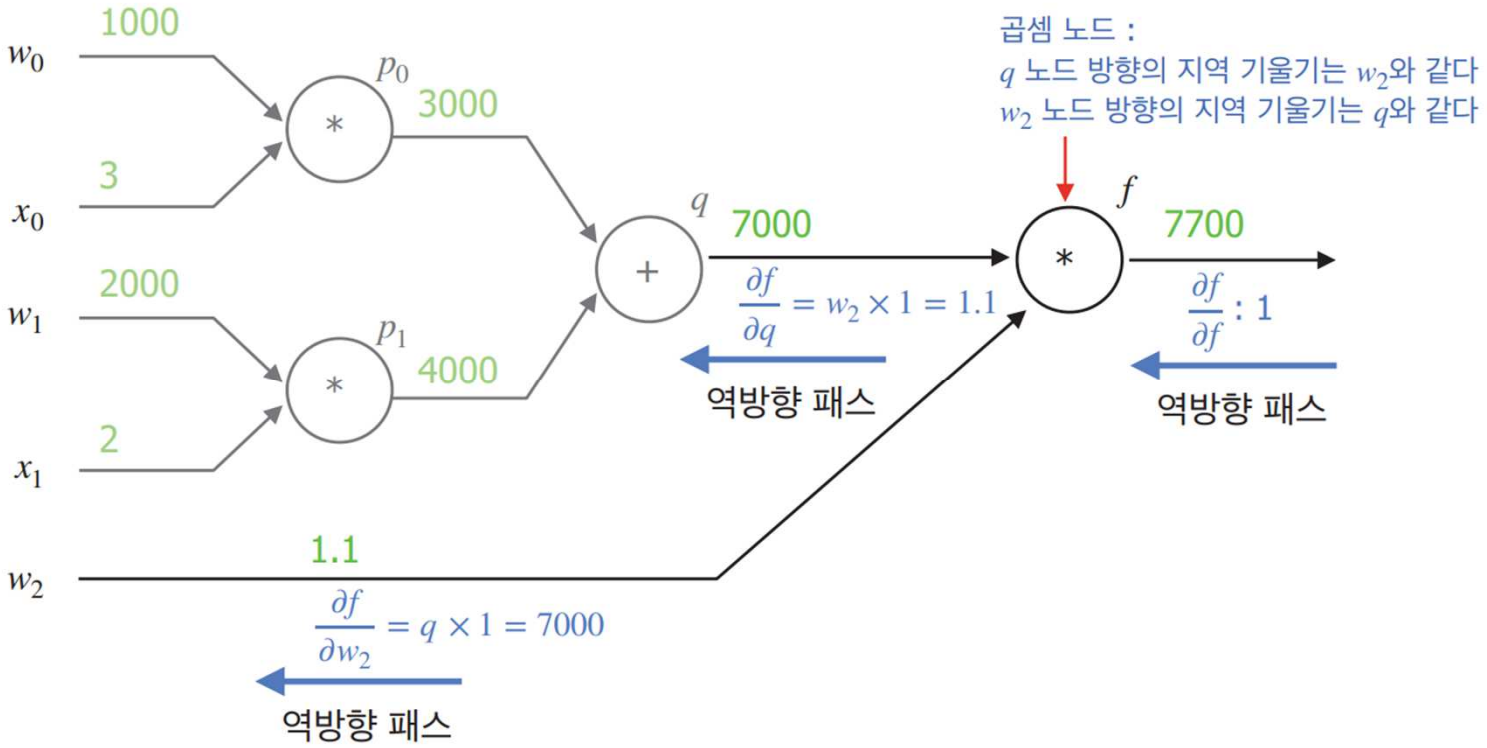
전체 계산 그래프를 만들기

- 이 수행 규칙에 따라 위의 계산 그래프에 대한 역전파 결과를 살펴보도록 하자.
  - 최종 노드는 출력 노드 f로, 이 출력을 f로 미분하면 1이 된다(규칙 1). 이제 이 미분값을 이전 단계 패스에 곱한다



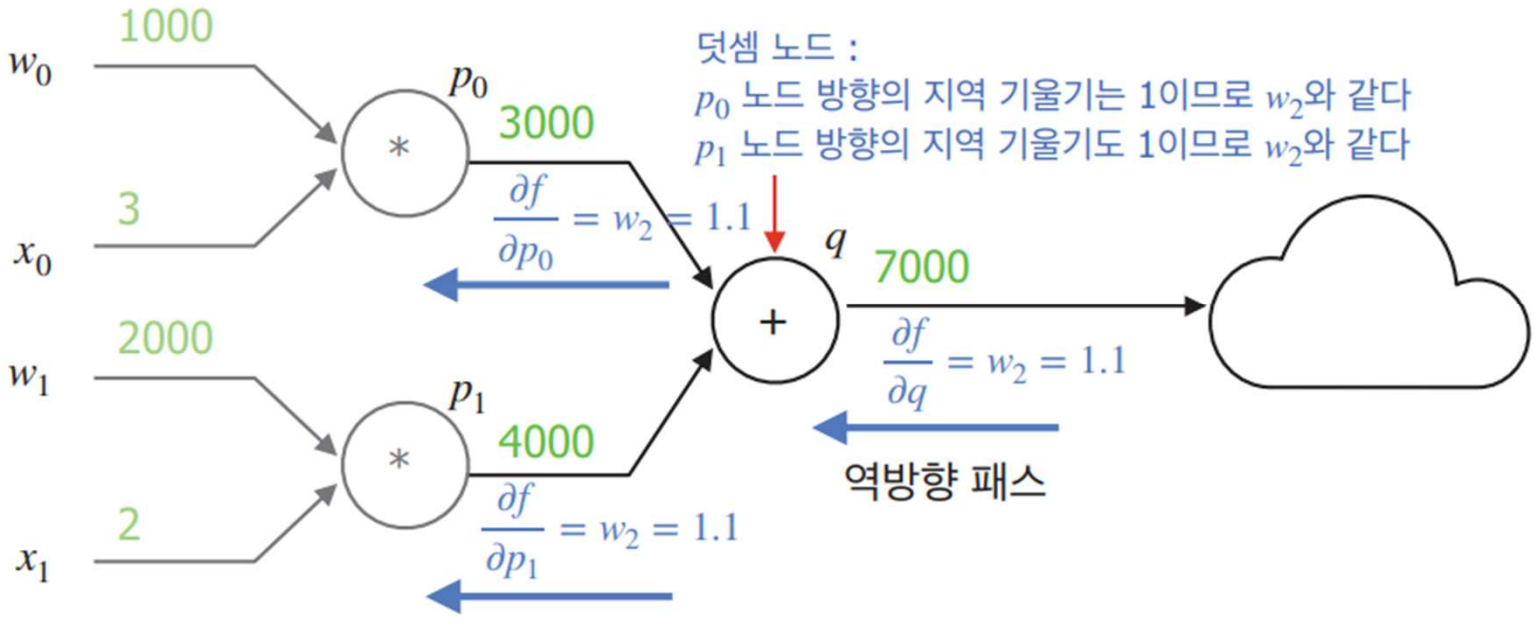
전체 계산 그래프를 만들기

- 다음으로 f = qω$_2$ 식으로 이루어진 f 노드를 q와 ω2로 각각 미분해 보자.
  - 이 노드는 곱셈 노드이므로 규칙 2가 적용된다. 이 규칙에 의해서 q 노드 방향의 지역 기울기는 ω$_2$와 같으며, ω$_2$ 노드 방향의 지역 기울기는 q와 같다



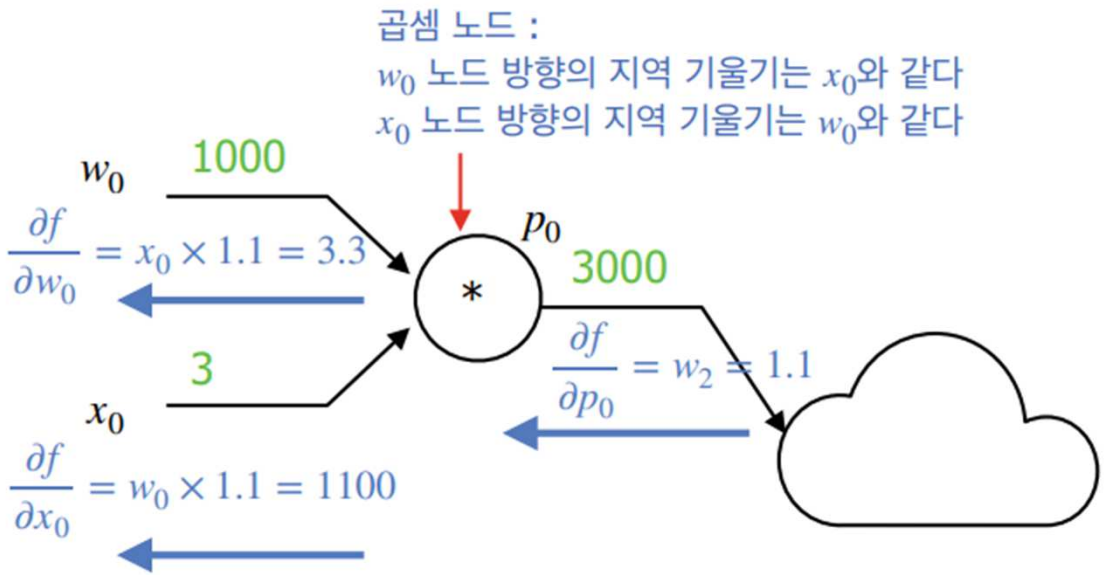
전체 계산 그래프를 만들기

- $q = p_0 + p_1$ 식으로 이루어진 q 노드의 미분을 알아보자.
  - 이 노드는 덧셈 노드이므로 규칙 3이 적용된다. 따라서 p_0 노드 방향의 지역 기울기는 1이므로 ω_2와 같다.
  - p_1 노드 방향의 지역 기울기도 1이므로 ω_2와 같다.
  - 이 결과는 위의 단순한 규칙을 적용한 것이기 때문에 계산에 드는 비용도 많지 않다



전체 계산 그래프를 만들기

- 다음 단계는 $p_0 = \omega_0 x_0$의 곱셈 식으로 된 p_0 노드이다.
  - 이 노드는 곱셈 노드이므로 역전파 수행 규칙 2가 적용된다.
  - 그림과 같이 ω_0 노드 방향의 지역 기울기는 x_0와 같으며, x_0 노드 방향의 지역 기울기는 ω_0와 같다. 역전파 규칙에 의해서 p_0 노드로 입력된 값이 1.1이므로 ω_0 노드 방향의 지역 기울기 1.1에 x_0를 곱한 3.3이 최종 기울기가 된다. 반면 x_0 방향의 기울기는 ω_0와 같기 때문에 이 지역 기울기 ω_0 값에 1.1을 곱한 1100이 전역 기울기 값이 된다.



전체 계산 그래프를 만들기

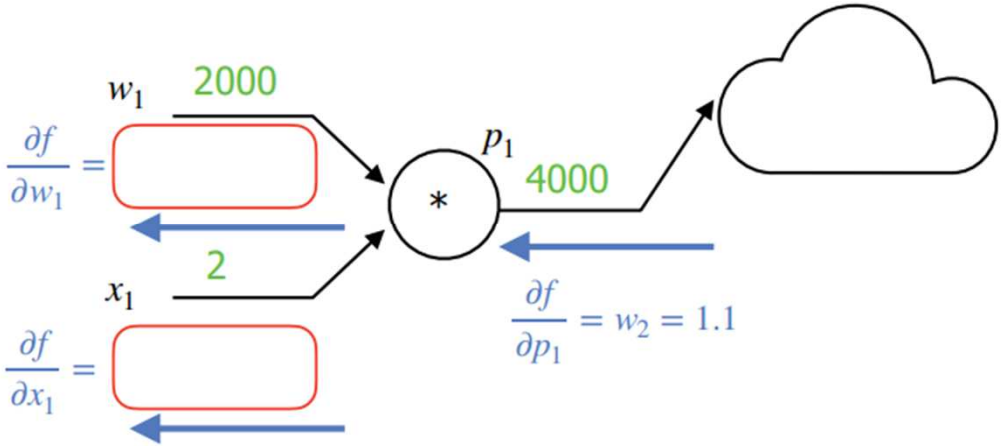
- 다음 도전 문제를 풀어보자

도전 문제 6.3: 역전파 수행 규칙을 적용해 보자

상 중 하



다음 그림은 $p_1 = \omega_1 x_1$의 곱셈 식으로 된 p_1 노드이다. 이 노드는 곱셈 노드이므로 역전파 수행 규칙 2가 적용된다. 빨간색 사각형 영역에 들어갈 올바른 식을 적어 보자.

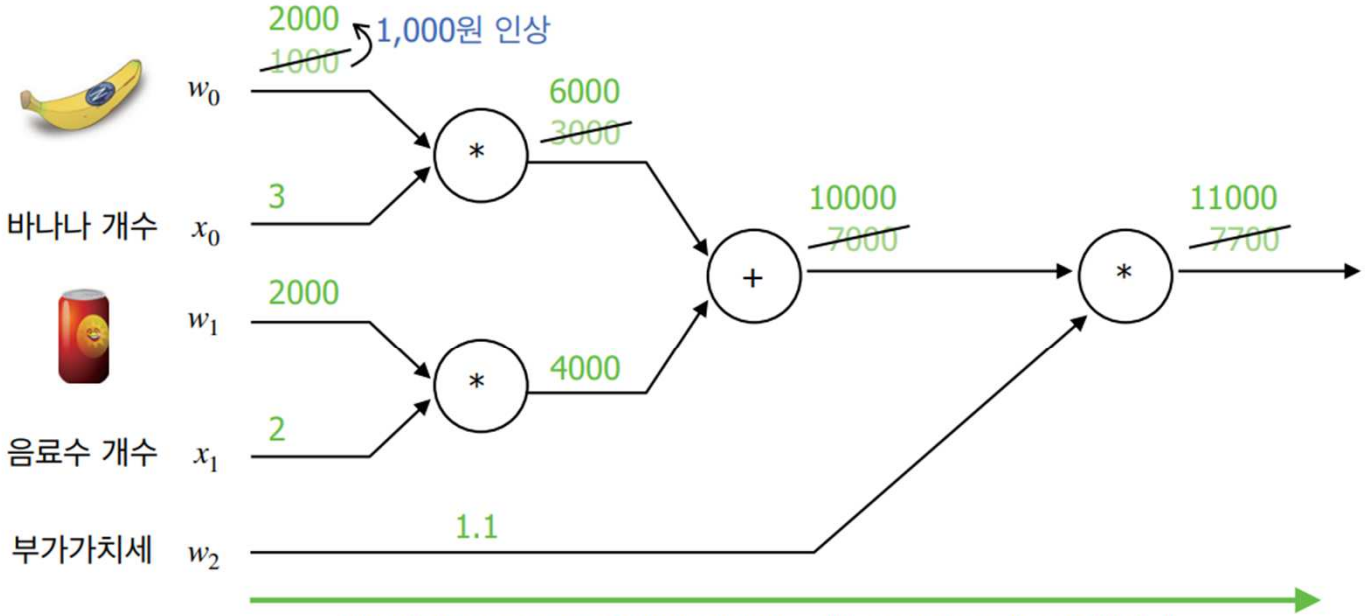


입력 노드에 대한 출력값의 영향을 어떻게 활용할까

- 이러한 계산 그래프와 지역 기울기를 바탕으로 입력값에 대한 출력값의 영향력을 구할 수 있다. 이제 다음과 같은 질문에 답해 보자

Q. 바나나의 가격 ω_0(입력값)이 1,000원에서 2,000원으로 인상되었다면 최종 출력값은 얼마인가?

A. 바나나의 가격이 2,000원으로 인상되면 그림과 같은 과정을 통해서 최종 출력값은 11,000원이 된다.



바나나의 가격이 2,000원일 때 계산 그래프의 순방향 패스와 계산 값:
최종 가격은 11,000원이 된다

입력 노드에 대한 출력값의 영향을 어떻게 활용할까

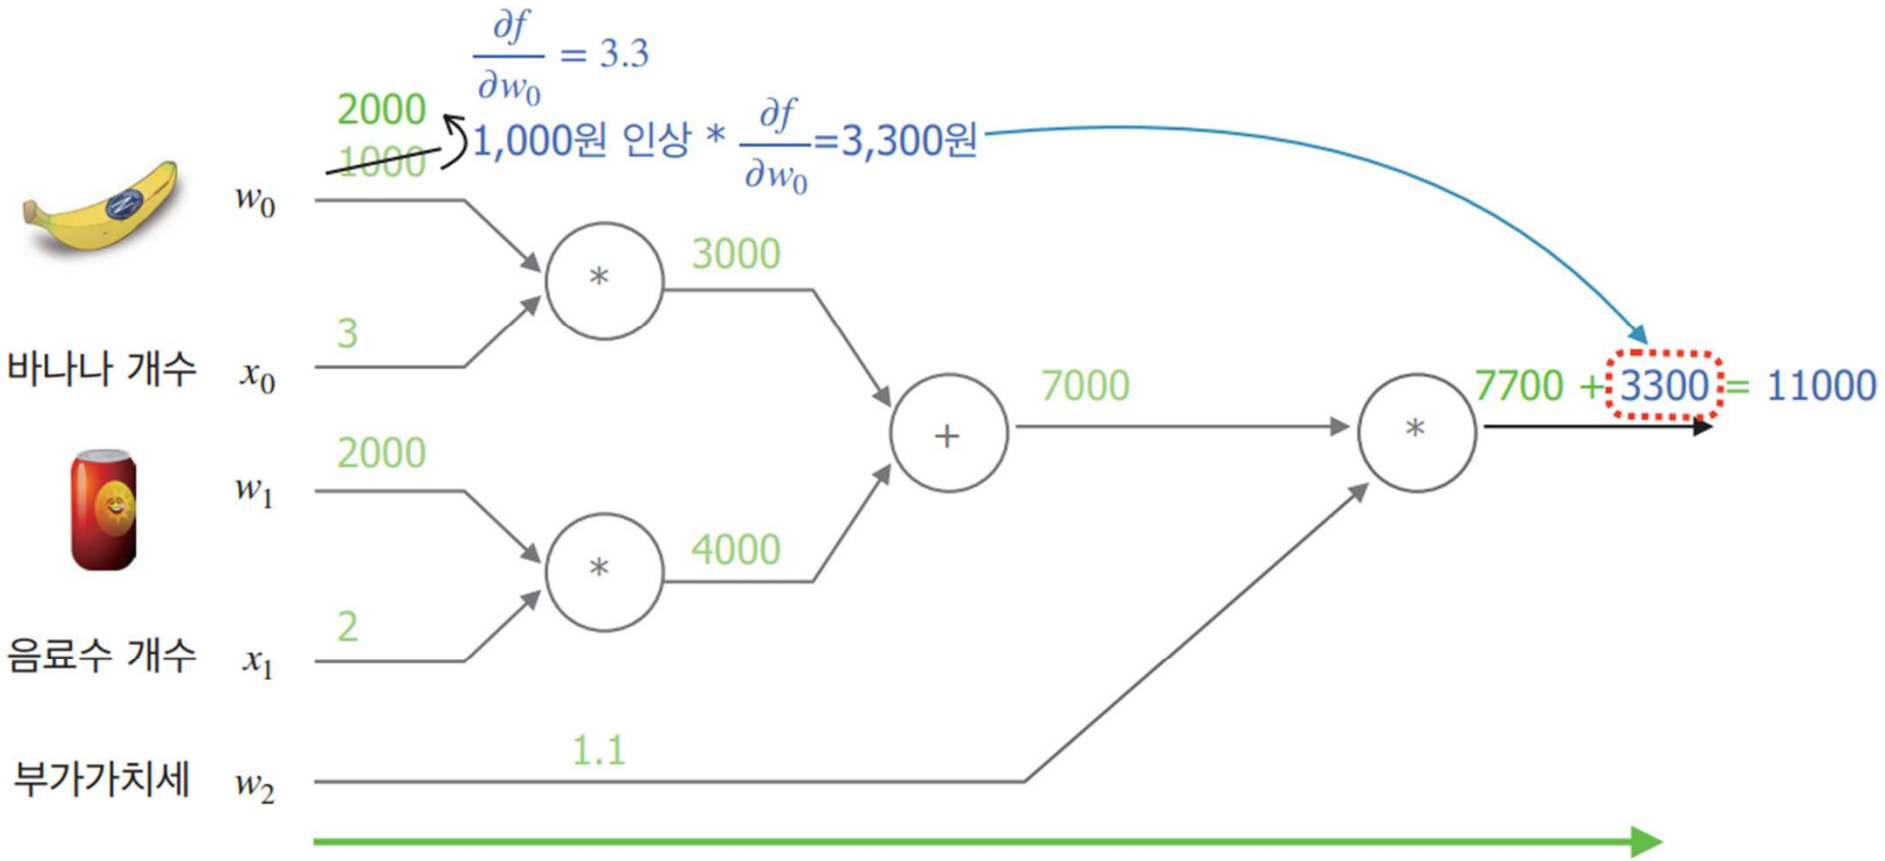
- 그림과 같이 ω_0의 값이 2,000원이 되면, 그 변동값이 각각의 노드에 전파되어 최종 가격은 11,000원 이 된다.
- 이제 다음과 같이 입력이 출력에 미치는 영향력을 이용하여 최종값을 구하는 방법을 알아보자. 이를 위하여 다음과 같은 질문이 주어진다

Q. 아래 계산 그래프에서 $\frac{\partial f}{\partial \omega_0}$가 3.3이므로 최종 출력에 미치는 영향력은 3.3이 될 것이다. 이 정보를 바탕으로 최종 출력값을 계산해 보자.

A. 바나나의 가격이 2,000원으로 인상되면 1,000원의 변동이 생긴다. 이 변동이 최종 출력에 미치는 영향력은 3.3이므로 3,300원의 인상 요인이 발생한다. 원래 가격은 7,700원이므로 3,300원을 더하면 11,000원이 최종값이 된다.

입력 노드에 대한 출력값의 영향을 어떻게 활용할까

- 이상의 내용에 대한 설명은 다음 그림을 통해서 쉽게 이해할 수 있다



입력 노드에 대한 출력값의 영향을 어떻게 활용할까

- 그림을 살펴보면 계산그래프의 입력 ω_0의 값이 2,000원으로, 1,000원이 인상되었다. 이 변동폭은 최종 출력 f에 얼마나 영향을 줄까?
  - 입력 ω_0의 f에 대한 영향은 $\frac{\partial f}{\partial w_0}$로 나타낼 수 있는데 이 값이 3.3 이므로 1000 * 3.3 = 3,300원이 출력에 영향을 미치게 된다.
  - 따라서 최종 값은 7700 + 3300이 되어 11,000원이 된다.
  - 이 영향력은 위에서 구한 순전파 과정의 결과와 동일하다

입력 노드에 대한 출력값의 영향을 어떻게 활용할까

- 다음 도전 문제를 풀어보자

도전 문제 6.4: 역전파 수행 규칙을 적용해 보자

상 중 하

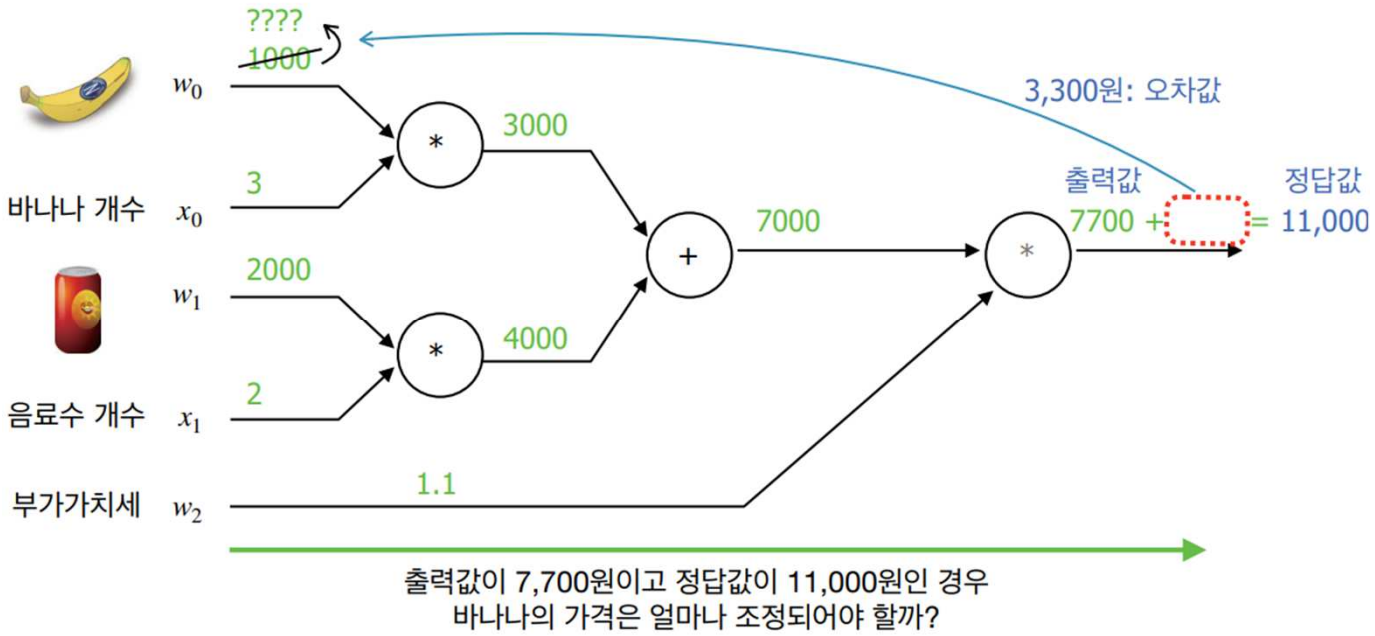


1. 이번에는 바나나의 수 x_0를 변경해 보자. 바나나의 수가 세 개가 아닌 네 개가 된다면 최종 가격은 얼마인가? 이 과정을 계산 그래프의 순전파 과정을 하나하나 밟아가면서 최종 가격을 계산해 보자.

2. 위의 순전파 과정 대신 $\frac{\partial f}{\partial x_0}$를 이용하여 최종 가격을 계산해 보자. 바나나의 수에 해당하는 입력 x_0의 f에 대한 영향은 $\frac{\partial f}{\partial x_0}$로 나타낼 수 있는데, 이 값을 이용하여 최종 가격을 계산해 보자. 최종 가격이 1.의 결과와 동일한지 비교해 보자.

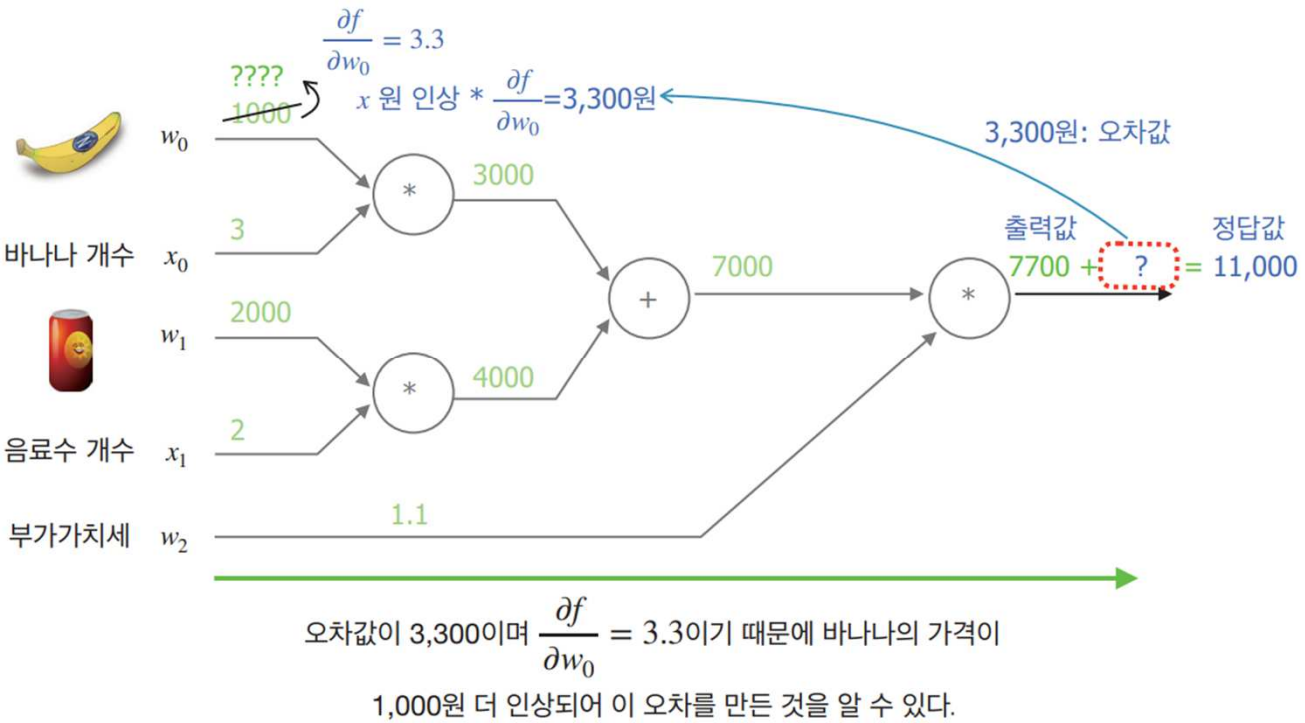
오차와 계산 그래프

- 위의 과정은 각 노드가 결과에 미치는 영향을 구하는 방법으로 유효한데, 딥러닝이 하는 일은 오차를 바탕으로 각 노드의 가중치를 계산하는 일이다.
  - 다음과 같은 상황을 가정해 보도록 하자.
  - 계산 그래프의 출력값($\hat{y}$)이 7,700원인데 실제 동윤이가 지불한 돈(t)이 11,000원이었다고 가정하자. 이 두 값의 오차는 3,300원인데 이 오차를 해결하기 위해서 바나나의 가격은 어떻게 조정되어야 할까?



오차와 계산 그래프

- 다른 물건의 가격이나 수를 조절하지 않는 단순한 상황을 가정한다면 바나나의 가격 변동이 최종 가격에 미치는 영향력만을 계산하면 될 것이다. 이 입력 ω_0의 f에 대한 영향은 $\frac{\partial f}{\partial w_0}$이며, 이 미분값은 이미 3.3으로 구해진 값이기 때문에 $x \times \frac{\partial f}{\partial w_0} = x \times 3.3 = 3300$ 과 같은 연산이 가능하다. 이 연산에 의해 x는 1,000원이라는 것을 알 수 있다.



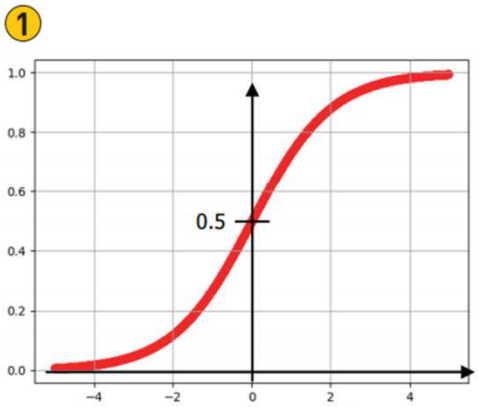
04 시그모이드 계층의 역전파

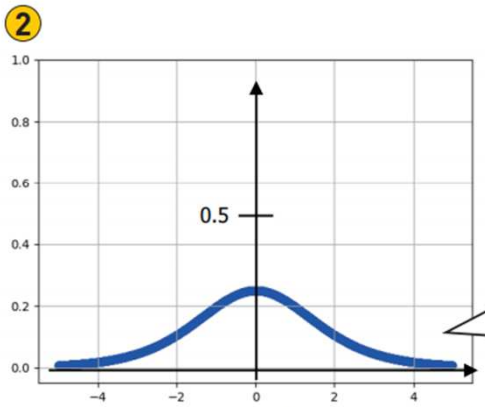
- 딥러닝 알고리즘의 핵심을 이루는 다층 퍼셉트론은 여러 입력값과 이 입력값에 대한 가중곱 그리고 이들의 합으로 이루어지며 이 가중합은 활성화 함수를 통해서 다음 단계로 전파된다.
  - 이제 입력된 값과 가중치의 곱 그리고 이들의 합으로 이루어진 노드는 이전 절에서 다룬 방법으로 역전파 단계의 미분값을 구할 수 있다.
- 이제 이 값들의 활성화 함수에 대한 미분과 역전파 과정을 살펴보도록 하자.
  - 딥러닝을 위한 활성화 함수는 여러 가지가 있으나 이 함수들 중에서 가장 기본이 되는 함수인 시그모이드 함수에 대해 우선 살펴보자.
  - 활성화 함수를 $\phi()$라고 할 때, 이 활성화 함수의 미분은 $\phi'()$ 로 표기하는데 이것만 안다면 입력 x, 출력 y, 목표값 t를 이용하여 가중치를 갱신하는 데 사용할 수 있다.
- 그런데 우리가 사용했던 **계단 함수는 미분이 불가능한 지점이 있고, 미분이 되는 곳에서도 미분치가 언제나 0**이다. 따라서 이 방법을 사용하기 위해서는 미분이 가능한 **새로운 활성화 함수**가 필요하다

04 시그모이드 계층의 역전파

- 신경망에서는 그림 1 과 같은 형태를 가지는 **시그모이드** sigmoid 함수를 활성화 함수로 도입한다.
  - 시그모이드 함수를 이전 장에서 표기한 계단 함수와 동일하게 $\phi()$ 로 나타낼 수 있다. 이 함수는 모 든 구간에서 미분이 가능해야 하며, 그 미분의 결과는 오른쪽 그림 2 에 나타난 바와 같이 모든 구 간에서 연속이다.
  - 이 함수 $\phi'()$ 는 다음과 같이 구현된다

$$\phi(x) = \frac{1}{1+e^{-x}} \qquad \phi'(x) = \frac{1}{1+e^{-x}}\left(1 - \frac{1}{1+e^{-x}}\right)$$





$$\phi'(x) = \phi(x)(1 - \phi(x))$$

시그모이드 함수와 이 함수의 미분 함수입니다. 두 함수는 모든 구간에서 연속인 함수이지요. 시그모이드 함수의 미분은 원래의 함수를 그대로 이용하여 표현할 수 있답니다.

시그모이드 함수: $\frac{1}{1+e^{-x}}$ 시그모이드 함수의 미분: $\frac{1}{1+e^{-x}}(1 - \frac{1}{1+e^{-x}})$

04 시그모이드 계층의 역전파

- 이 함수는 미분이 가능하다는 장점과 함께, 또 하나의 큰 장점이 있다.
  - 이 **함수의 미분은** 다음과 같이 **원래의 함수를 이용하여 표현**할 수 있다.

$$\phi'(x) = \phi(x)(1 - \phi(x))$$

- 활성화 함수로 시그모이드 함수를 사용하게 되면 이와 같이 간단하게 미분을 구할 수 있다는 장점 이 있으나 다른 단점이 많아서 효율적이지 않다.

시그모이드 함수의 미분과 계산 그래프

- 시그모이드 함수는 미분의 결과가 자기 자신 $\phi(x)$ 곱하기 $(1-\phi(x))$의 간단한 모양으로 되어 있는 데 어떻게 해서 이렇게 간단하게 나타날까?
  - 시그모이드 함수를 $\phi(x)$ 로 나타내고 이 함수를 미분하 는 단계를 하나하나 표기하면 다음과 같이 되는 것을 볼 수 있다.
  - 이와 같은 결론이 나오는 이유는 $\phi(x) = \frac{1}{(1+e^{-x})}$ 함수가 가지는 특수한 형태 때문이다.

$$\frac{d}{dx}\phi(x) = \frac{d}{dx}(1+e^{-x})^{-1}$$

$$= (-1)\frac{1}{(1+e^{-x})^2}\frac{d}{dx}(1+e^{-x})$$

$$= (-1)\frac{1}{(1+e^{-x})^2}(0+e^{-x})\frac{d}{dx}(-x)$$

$$= (-1)\frac{1}{(1+e^{-x})^2}e^{-x}(-1)$$

$$= \frac{e^{-x}}{(1+e^{-x})^2}$$

$$= \frac{1+e^{-x}-1}{(1+e^{-x})^2}$$

$$= \frac{(1+e^{-x})}{(1+e^{-x})^2} - \frac{1}{(1+e^{-x})^2}$$

$$= \frac{1}{(1+e^{-x})} - \frac{1}{(1+e^{-x})^2}$$

$$= \frac{1}{(1+e^{-x})}\left(1 - \frac{1}{(1+e^{-x})}\right) = \phi(x)(1-\phi(x))$$

시그모이드 함수의 미분과 계산 그래프

- 시그모이드 함수는 그림과 같이 여러 노드로 이루어진 계산 그래프로도 나타낼 수 있다.
  - 이 계산 그래프는 $\phi(x) = \frac{1}{(1+e^{-x})}$ 의 순방향 계산 과정인데, e^x 계산을 exp 노드로 표현하였다.
  - 계산 그래프의 입력이 1.0이 될 경우 *–1 노드의 계산 결과값은 –1.0, exp 노드의 계산 결과값은 0.37($e^{-1.0}$), +1 노드의 계산 결과값은 1.37, 마지막 노드 1/x의 결과값은 0.73이 되는 것을 알 수 있다.



$\phi(x) = \frac{1}{1 + e^{-x}}$ 함수의 순방향 계산

시그모이드 함수의 미분과 계산 그래프

- 이 계산 그래프의 출력은 다음과 같은 코드로 간단하게 확인할 수 있다.
  - 노드의 이름은 n0부터 n1, n2, n3, n4로 각각 부여하였다.

```
import math


n0 = 1.0
print('n0 =', n0)
n1 = n0 * -1.0
print('n1 =', n1)
n2 = math.e ** (n1)  # e**(-1)
print('n2 =', n2)
n3 = n2 + 1
print('n3 =', n3)
n4 = 1/n3
print('n4 =', n4)
```

```
n0 = 1.0
n1 = -1.0
n2 = 0.36787944117144233
n3 = 1.3678794411714423
n4 = 0.7310585786300049
```

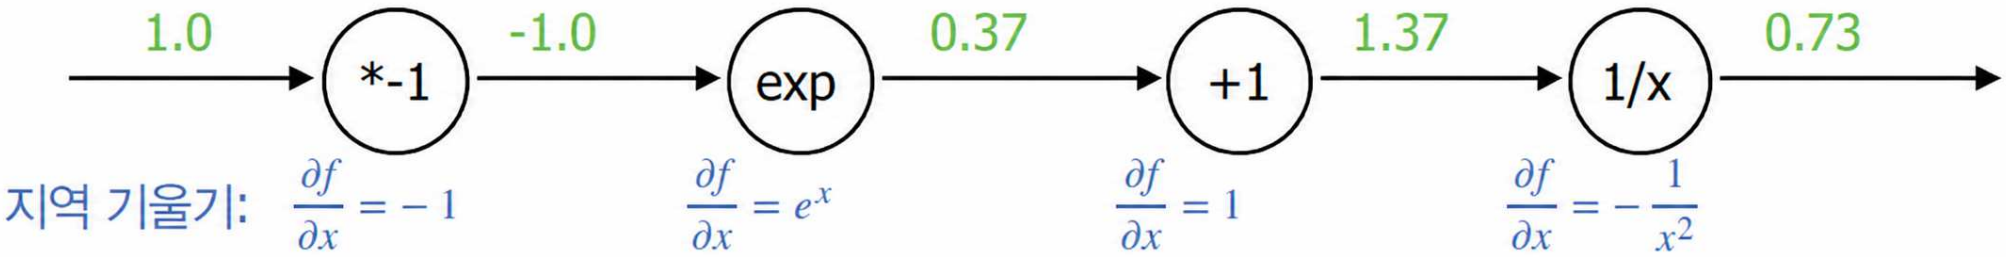
시그모이드 함수의 미분과 계산 그래프

- 이 함수의 순전파 단계에서 지역 기울기를 구해 두면, 이 지역 기울기를 역전파 계산 단계에서 차례로 활용할 수 있다.
- 이 계산 그래프에서 사용된 노드의 연산들을 함수 f(x)로 나타낼 때, 이 함수에 대한 도함수를 구하면 다음과 같다.

함수	도함수	함수	도함수
$f(x) = e^x$	$\frac{\partial f}{\partial x} = e^x$	$f(x) = \frac{1}{x}$	$\frac{\partial f}{\partial x} = -\frac{1}{x^2}$
$f(x) = ax$	$\frac{\partial f}{\partial x} = a$	$f(x) = x + c$	$\frac{\partial f}{\partial x} = 1$

시그모이드 함수의 미분과 계산 그래프

- 표를 바탕으로 각 노드의 미분값을 구할 수 있으며, 이 미분(지역 기울기)은 다음과 같이 차례대로 구할 수 있다.
- 이 지역 기울기는 역방향 계산을 위해서 *-1 노드, exp 노드, +1 노드, 1/x 노드 각각에 대해서 구해야 한다.



시그모이드 함수의 미분과 계산 그래프

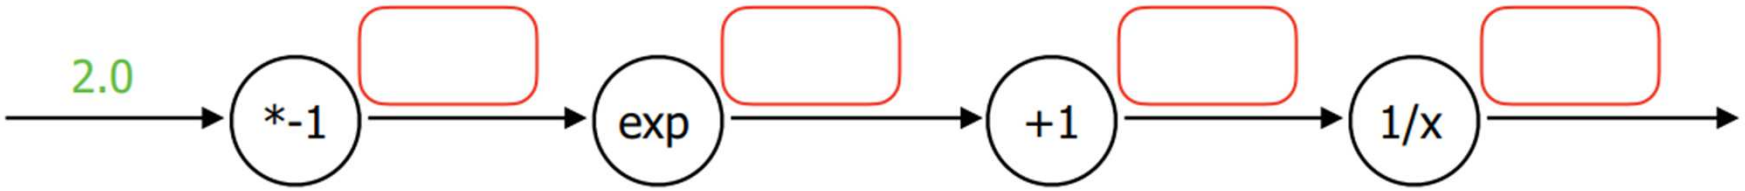
- 다음 도전 문제를 풀어보자

도전 문제 6.5: 시그모이드 함수의 순방향 계산 그래프

상 중 하



1. 다음 그림은 $\phi(x) = \frac{1}{1+e^{-1}}$의 순방향 계산 과정의 초기 입력값이 2.00이다. 빨간색 사각형 상자에 들어갈 올바른 식을 적으시오.

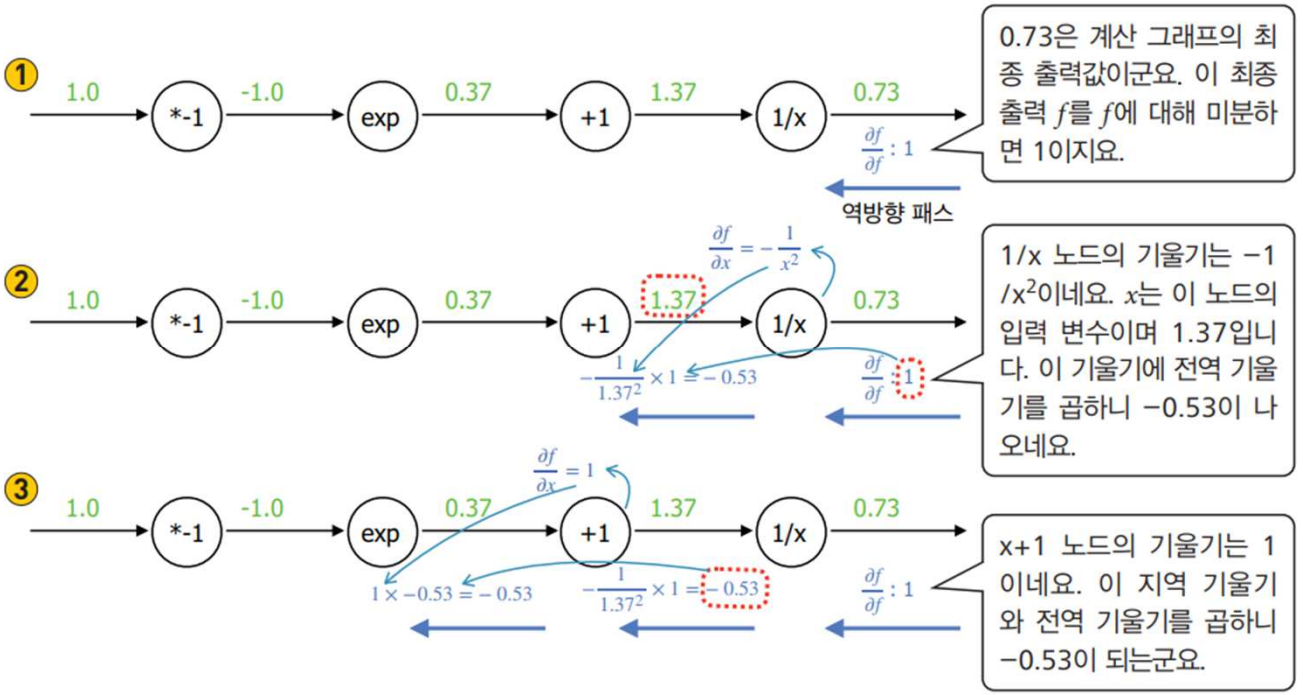


$\phi(x) = \frac{1}{1 + e^{-x}}$ 함수의 순방향 계산

2. 이 계산 과정을 파이썬 코드로 구현하여 각 단계의 값을 출력하여라.

시그모이드 함수의 미분과 계산 그래프

- 그림 1 은 $\frac{\partial f}{\partial f}$이며, 이 값은 당연히 1이 된다.
- 그림 2 에 나타난 1/x 노드의 역방향 계산 값은 $\frac{\partial y}{\partial x} = -\frac{1}{x^2}$이다.
  - 이 계산식에서 x는 1/x 노드의 입력값 1.37이다. 따라서 이 값 $-\frac{1}{1.37^2}$ 에 전역 기울기 1 을 곱한 $-\frac{1}{1.37^2} \times 1$이 지역 기울기값이며, 이는 -0.53이다.
  - 이와 같은 방법으로 그림 3 과 같은 값을 얻을 수 있다.



시그모이드 함수의 미분과 계산 그래프

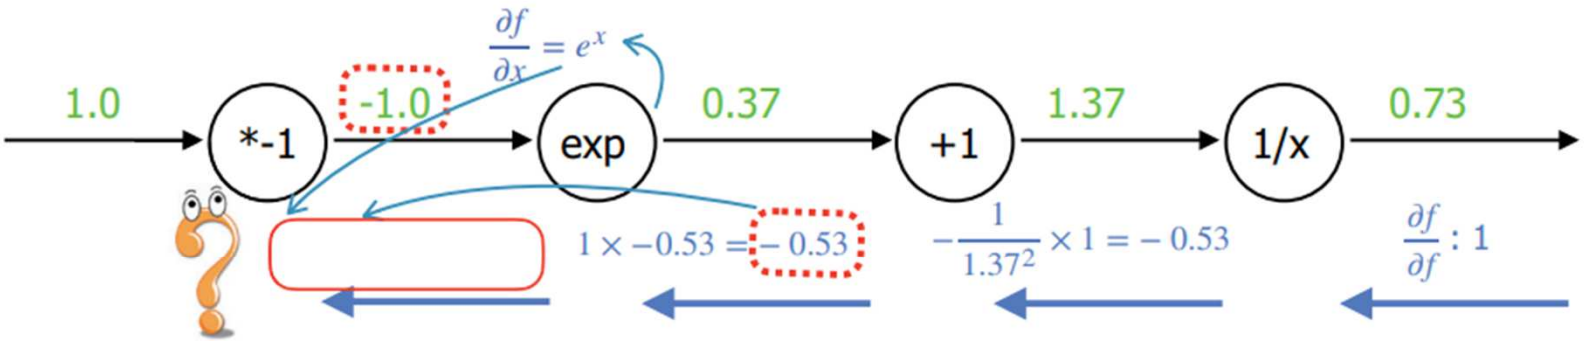
- 다음 도전 문제를 풀어보자

도전 문제 6.6: 시그모이드 함수의 역방향 계산 그래프

상 중 하



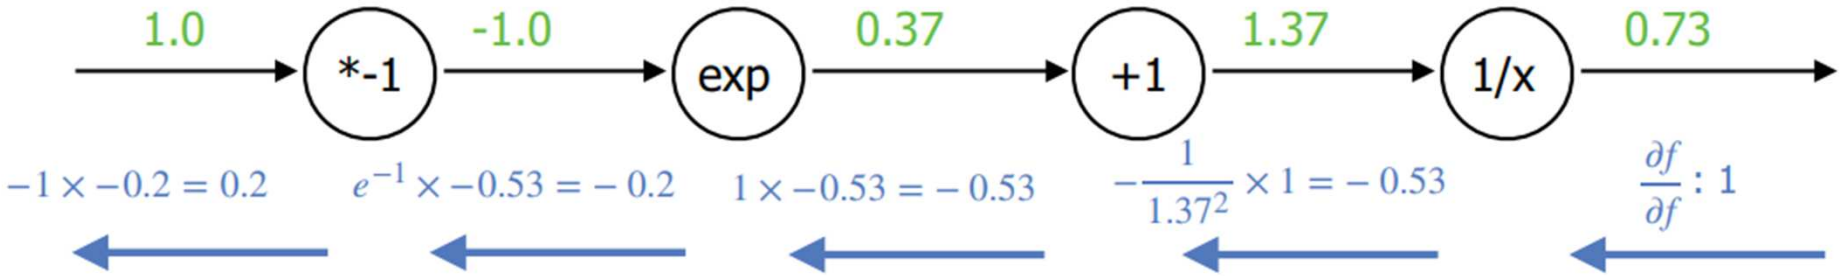
1. 다음 그림은 $\phi(x) = \frac{1}{1+e^{-1}}$의 역방향 계산 과정이다. 빨간색 사각형 상자에 들어갈 exp 노드의 전역 기울기를 계산하여라.



2. 위의 문제에서 *−1 노드의 전역 기울기를 계산하여라.

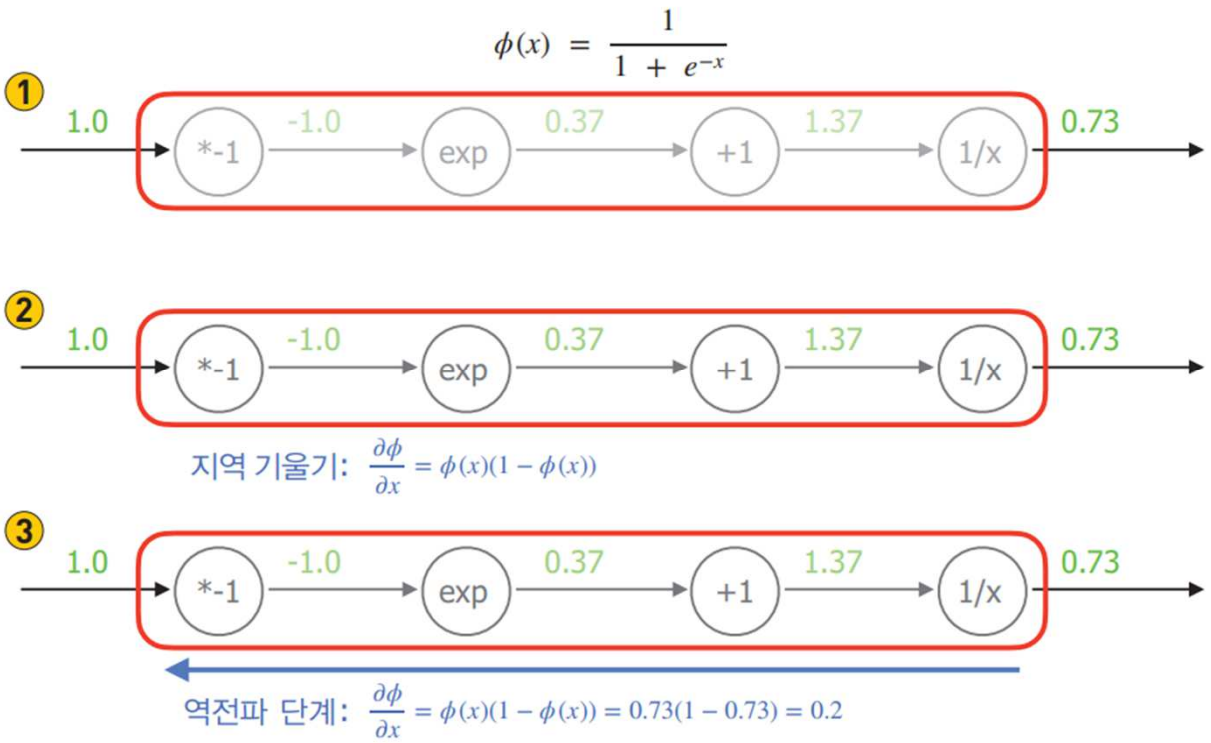
시그모이드 함수의 미분과 계산 그래프

- 이러한 과정을 통해 *-1 노드에 대한 전역 기울기까지 구하게 되면 그림과 같이 0.2가 나타난다.



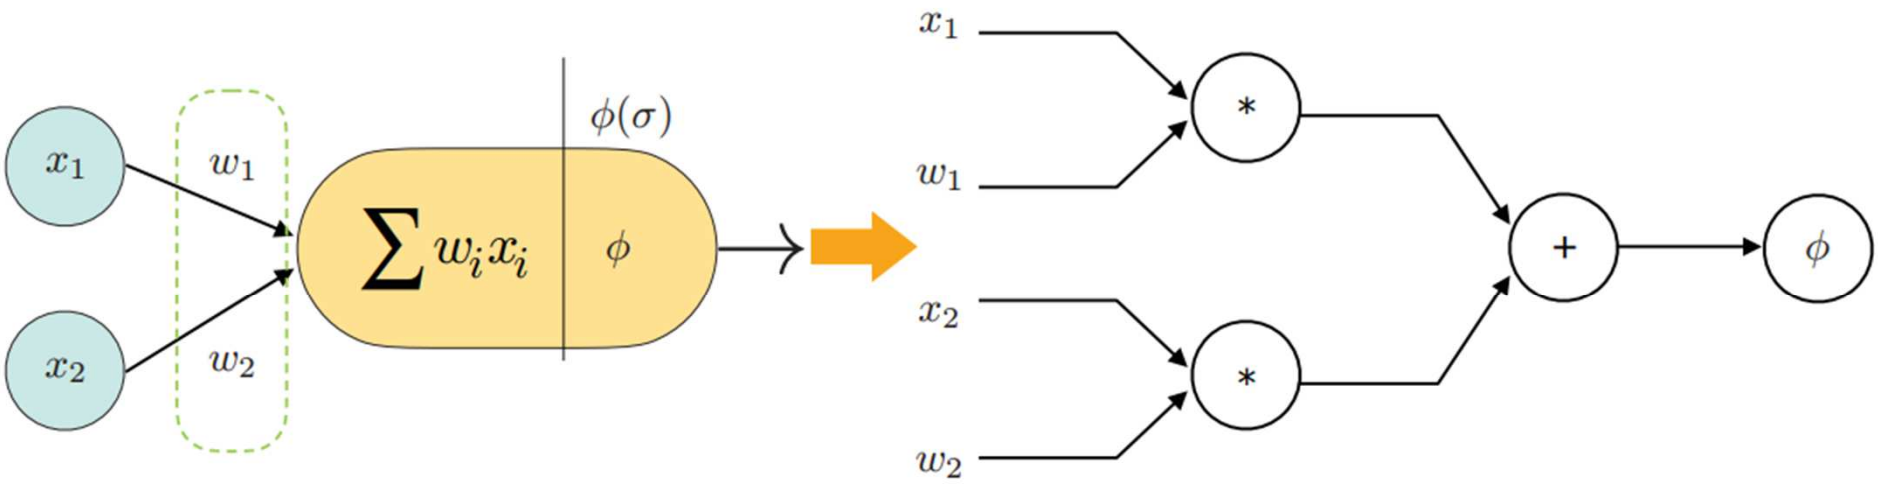
시그모이드 함수의 미분과 계산 그래프

- 시그모이드 함수를 활성화 함수로 이용하기 좋은 점은 위와 같은 복잡한 과정을 매우 간단하게 구할 수 있다는 점이다.
- 다음 그림 1 에서 빨간색 사각형 영역은 $\phi(x)$ 함수이며, 순전파 과정에서 그림 2 와 같이 지역 기울기를 구할 수 있다. 이 지역 기울기는 $\phi(x)(1-\phi(x))$ 로 나타낼 수 있다.



퍼셉트론의 구조와 계산 그래프 그리고 오차 역전파의 혁신

- 우리가 다룬 퍼셉트론의 계산 방식은 아래 그림과 같이 계산 그래프로 표현할 수 있으며 많은 층을 가진 다층 퍼셉트론 역시 계산 그래프를 연속적으로 연결하면 구현할 수 있다.
- 계산 그래프에서 순전파 단계를 밟아가며 지역 기울기를 구하는 과정 역시 퍼셉트론의 연산 과정과 동일하다.
  - 퍼셉트론의 구조에 나타난 대부분의 연산은 계산 그래프의 덧셈 노드, 곱셈 노드, 활성화 함수 노드이므로 이들의 미분 역시 어렵지 않게 구할 수 있을 것이다



퍼셉트론의 구조

계산 그래프로 표현한 퍼셉트론의 구조

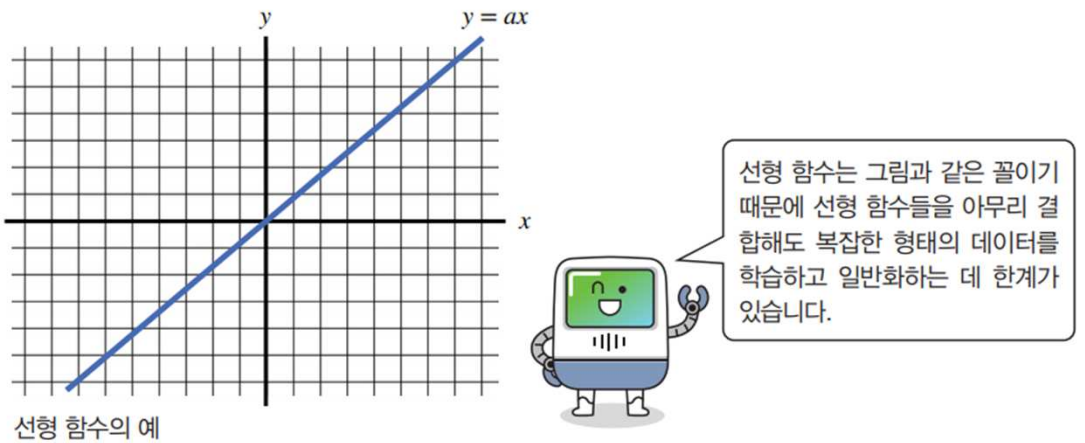
퍼셉트론의 구조와 계산 그래프 그리고 오차 역전파의 혁신

- 오차 역전파 알고리즘은 딥러닝 연구와 발전에 결정적인 역할을 했다.
  - 그 영향을 정리하면 다음과 같다.

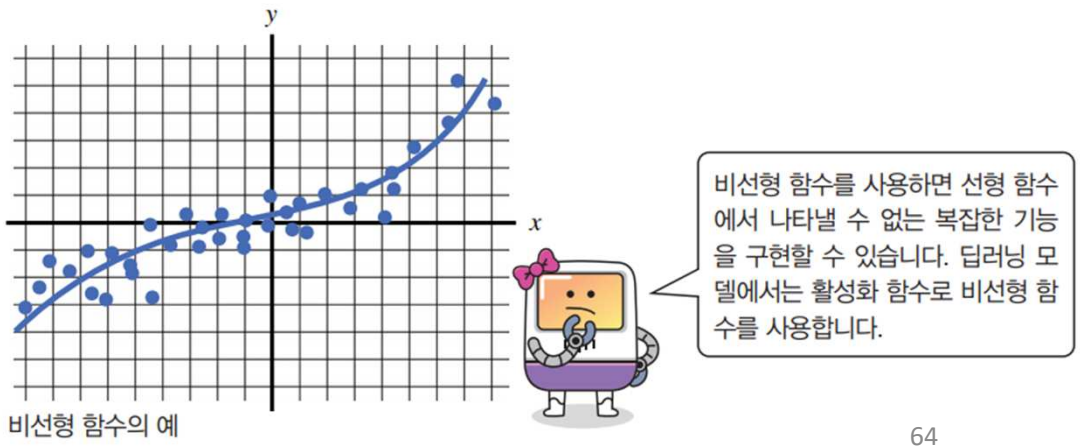
- **심층 신경망의 효율적인 학습:** 오차 역전파 이전의 전통적인 방법으로는 심층 신경망의 가중치를 효율적으로 학습시키기 어려웠다. 오차 역전파는 출력층에서 발생한 오차를 입력층까지 거꾸로 전파하면서 각 층의 가중치를 업데이트하는 방법을 제공하였으며, 이 알고리즘으로 인하여 비로소 심층 신경망을 효율적으로 학습시킬 수 있게 되었다.
- **딥러닝의 부흥:** 1980년대에 제안되어 2000년대 초에 재발견된 오차 역전파는 딥러닝의 성장을 촉진시켰다. 이 알고리즘의 효율성 덕분에 많은 층을 가진 복잡한 신경망을 학습시키는 것이 가능해졌다.
- **활성화 함수의 중요성이 부각됨:** 역전파 과정에서 활성화 함수의 미분값은 중요한 역할을 한다. 이러한 중요성을 인식하고 더 나은 활성화 함수의 개발에 집중한 결과, ReLU와 같은 새로운 활성화 함수들이 제안되었고, 이런 함수들이 오늘날 널리 쓰이게 되었다.
- **최적화 기법의 발전:** 오차 역전파는 기본적으로 경사하강법에 기반한다. 이를 통해 다양한 최적화 기법들(Adam, RMSprop 등)이 연구되고 개발되었다.
- **다양한 네트워크 구조의 발전:** 오차 역전파는 연쇄 법칙을 사용하여 다층 신경망의 가중치를 갱신한다. 이 원리는 다양한 신경망 구조에도 확장 적용이 가능하여, 합성곱 신경망(CNN), 순환 신경망(RNN) 등 다양한 심층 신경망 구조가 등장하는 데에도 큰 기여를 하였다.
- **딥러닝 프레임워크의 등장과 확산:** 구글의 텐서플로, 메타의 파이토치와 같은 딥러닝 프레임워크는 자동 미분 기능을 통해 오차 역전파를 손쉽게 구현할 수 있게 해준다. 이러한 프레임워크들은 역전파 알고리즘의 원리를 기반으로 동작하며 딥러닝을 빠르게 구현하는 데 사용되고 있다.

05 ReLU 함수

- 활성화 함수의 중요성
  - 활성화 함수는 딥러닝 알고리즘에서 매우 중요한 역할을 한다. 이 함수는 각 뉴런의 출력을 결정하 는 데 사용되며, 딥러닝 모델의 비선형성을 만들어 주는 주요 요소이다.
  - 딥러닝 모델은 인간의 신경 세포를 모방한 여러 개의 층으로 이루어져 있다. 각 층의 뉴런은 입력에 대한 가중합을 계산한 후 활성화 함수를 통해 그 결과를 변환한다. 이 변환된 출력은 다음 층의 입력으로 전달되며, 이 과정 을 모델의 모든 층에 대해 반복하게 되는 구조이다.



선형 함수의 예



비선형 함수의 예

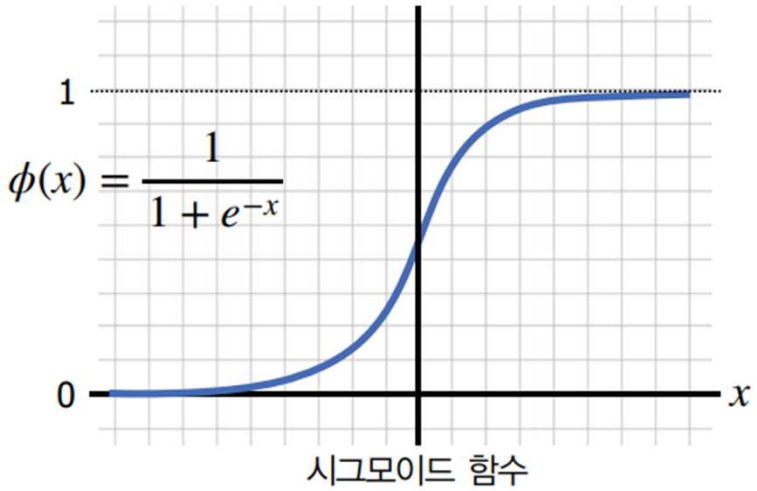
활성화 함수의 중요성

- 이러한 딥러닝 모델에서 활성화 함수의 주요 역할은 다음과 같다.

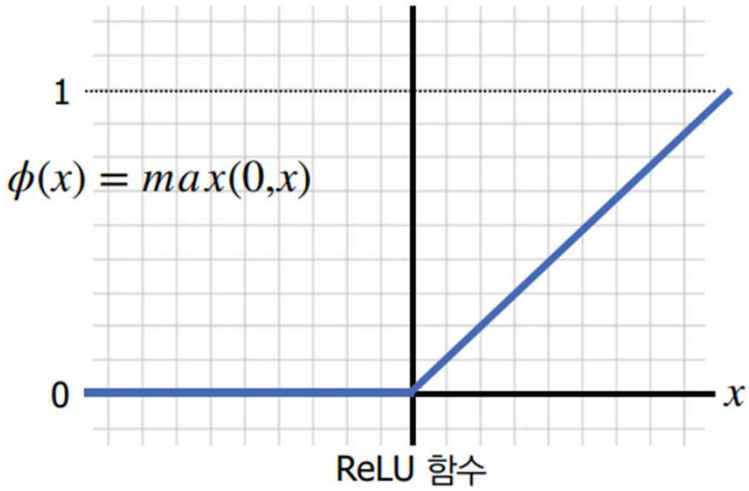
- **비선형성 추가:** 현실 세계의 많은 문제들은 XOR 문제와 같이 대부분 비선형적인 성질을 가지고 있다. 선형 함수를 사용하면 이러한 복잡성을 구현할 수 없다. 따라서 비선형 활성화 함수를 통해 모델이 복잡한 패턴을 학습하고 일반화하는 능력을 향상시킬 수 있다.
- **복잡한 결정 경계 생성:** 활성화 함수는 뉴런의 출력을 결정하는 임계값 역할을 한다. 이를 통해 딥러닝 모델은 복잡한 결정 경계를 형성할 수 있어 다양한 클래스 사이에서 구분을 할 수 있다.
- **역전파를 위한 오차의 기울기 제공:** 활성화 함수는 오차 역전파 과정에서 매우 중요한 역할을 한다. 오차 역전파 단계의 가중치를 업데이트하기 위해 오차를 이전 층으로 전파하는 경우, 이전에 다룬 바와 같이 활성화 함수의 미분값이 필요하다. 이를 통해 각 가중치에 대한 오차의 기울기를 계산하고, 그 기울기를 사용해 가중치를 업데이트할 수 있다. 이러한 오차의 기울기 계산에서 활성화 함수는 큰 역할을 한다.

활성화 함수의 중요성

- 딥러닝 알고리즘에서 주로 사용되는 활성화 함수에는 **시그모이드 함수**, **ReLU** Rectified Linear Unit **함수**, 하이퍼볼릭 탄젠트 함수 등이 있다.
  - 이들은 각각 다른 성질과 특징을 가지고 있어, 특정 문제에 대한 모델의 성능을 개선하는 데 도움이 될 수 있다.
- ReLU 함수는 Rectified Linear Unit 함수의 약자로, 우리말로 **정류 선형 함수** 또는 **경사함수**라고도 부른다.
  - 이 함수는 매우 간단한 비선형 함수로, 입력값이 0 이상일 때는 입력값을 그대로 출력하고, 0보다 작을 때는 0을 출력한다. 수식으로 표현하면 f(x) = max(0, x)와 같으며, 그림으로 나타내면 다음과 같다



시그모이드 함수



ReLU 함수

활성화 함수의 중요성

- 지난 수십 년간 널리 사용된 **시그모이드 함수**는 자극이 가장 적을 경우 0을 출력하고, 가장 큰 경우 1을 출력하며 매끄러운 곡선 형태로 되어 있어서 어느 구간에서든 미분이 가능하다는 특징이 있다.
  - 이러한 좋은 성질에도 불구하고 다음과 같은 심각한 한계가 있어서 이를 사용한 딥러닝 모델은 좋은 성과를 내지 못했다.

- **기울기 소실** Vanishing Gradient **문제:** 시그모이드 함수는 그 출력이 0 또는 1에 가까워질수록 기울기가 거의 0에 가까워진다. 따라서 신경망이 깊어질수록 오차의 역전파가 제대로 이루어지지 않는 기울기 소실 문제가 발생하게 된다. 즉, 신경망이 깊어질수록 맨 처음 층까지 오차가 전달되지 않아 학습이 잘 이루어지지 않을 수 있다.
- **출력이 0에서 1 사이로 한정됨:** 시그모이드 함수의 출력은 0과 1 사이의 값이다. 이는 신경망의 출력이 항상 양수라는 것을 의미하며, 중심이 0이 아니라는 문제를 가지고 있으며, 학습의 어려움을 초래할 수 있다.
- **높은 계산 비용:** 시그모이드 함수는 지수함수를 포함하므로 컴퓨터로 구현할 때 계산 비용이 높다. 컴퓨터는 실수 연산과 지수함수 연산을 할 경우, 정수 연산보다 수십 배 이상 더 많은 계산을 해야 한다. 이러한 높은 계산 비용으로 인하여 학습 속도를 느리게 만들 수 있다.

활성화 함수의 중요성

- 넘파이를 이용하여 시그모이드 함수를 구현하고 간단한 값을 주어 출력을 살펴보자.

```
import numpy as np
import matplotlib.pyplot as plt

def sigmoid(x):
    return 1 / (1 + np.exp(-x))

print('sigmoid(-2) :', sigmoid(-2))
print('sigmoid(-1) :', sigmoid(-1))
print('sigmoid( 0) :', sigmoid(0))
print('sigmoid( 1) :', sigmoid(1))
print('sigmoid( 2) :', sigmoid(2))
```

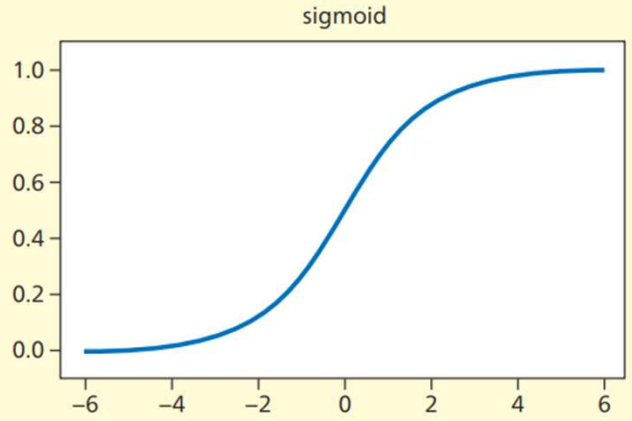
```
sigmoid(-2) : 0.11920292202211755
sigmoid(-1) : 0.2689414213699951
sigmoid( 0) : 0.5
sigmoid( 1) : 0.7310585786300049
sigmoid( 2) : 0.8807970779778823
```

활성화 함수의 중요성

- 아래와 같은 코드로 이 함수를 시각화해 보자.
  - 이 함수의 입력값은 –6에서 6 사이의 값이다

```
inputs = np.arange(-6.0, 6.0, 0.1)    # 입력값의 범위
outputs = sigmoid(inputs)

plt.figure(figsize=(5, 3))
plt.plot(inputs, outputs)
plt.ylim(-0.1, 1.1)
plt.title('sigmoid',fontsize=12)
plt.show()
```



활성화 함수의 중요성

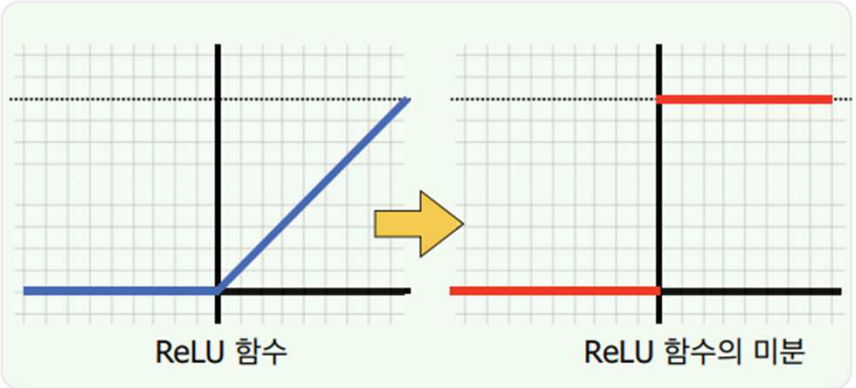
- 이제 살펴볼 ReLU 함수는 딥러닝 모델에서 널리 사용되는 활성화 함수 중 하나로, 특히 더 깊은 신경망에서 시그모이드 함수보다 더 좋은 성능을 보이고 있다.
  - 그 이유는 다음과 같다.

- **기울기 소실 문제 감소:** 시그모이드 함수는 입력의 절대값이 클 때 출력이 0 또는 1에 매우 가까워지므로, 이 경우 그 미분값이 거의 0에 가까워진다. 따라서 역전파 과정에서 기울기가 0에 가까워지면, 가중치 업데이트가 제대로 이루어지지 않는 '기울기 소실' 문제가 발생할 수 있다. 반면 ReLU 함수는 양수 입력에 대해서는 기울기가 항상 1이므로, 이러한 문제를 효과적으로 완화할 수 있다.
- **계산 효율성:** ReLU 함수는 0 이하일 때 0, 0 이상일 때 입력값을 그대로 출력하는 매우 간단한 함수이다. 이는 연산 비용이 매우 낮다는 것을 의미한다. 따라서 크고 복잡한 모델에서 훨씬 빠른 학습 속도를 가능하게 한다. 반면, 시그모이드 함수는 지수함수를 포함하므로 계산 비용이 더 높다.

활성화 함수의 중요성

- 다음 그림은 시그모이드 함수와 이 함수의 미분 그리고 ReLU 함수와 이 함수의 미분을 시각적으로 나타낸 것이다.
  - 시그모이드 함수의 경우 미분값이 0에서 1 사이이며 특정한 구간을 제외하면 나머지 구간에서 0에 가까운 값을 가진다. 따라서 역전파를 거치면서 점점 0에 수렴하는 **기울기 소실** 문제가 발생할 가능성이 매우 높다.
- 오른쪽의 ReLU 함수의 미분은 0 또는 1의 값을 가진다.
  - 이 함수를 자세히 보면 양수값이 입력으로 들어올 경우, 그 값에 대한 미분값은 항상 1을 가지는 것을 볼 수 있다.
- 따라서 역전파 단계에서 활성화 함수에 대하여 편미분을 하더라도 **기울기 소실 문제 가 발생할 가능성이 시그모이드 함수에 비하여 더 낮다.**





ReLU 함수를 그려보자

- 넘파이를 이용하여 ReLU 함수를 구현하고 간단한 값을 주어 출력을 살펴보자.
  - ReLU(x) 함수는 입력 x가 0보다 작으면 0을 반환하고, 그렇지 않을 경우 x 값을 반환하는 한 줄짜리 함수이다.

```
import numpy as np
import matplotlib.pyplot as plt

def ReLU(x):
    return np.maximum(0, x)

print('ReLU(-2) :', ReLU(-2))
print('ReLU(-1) :', ReLU(-1))
print('ReLU( 0) :', ReLU(0))
print('ReLU( 1) :', ReLU(1))
print('ReLU( 2) :', ReLU(2))
```

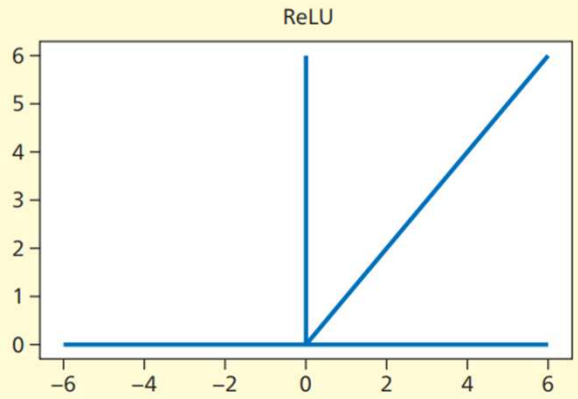
```
ReLU(-2) : 0
ReLU(-1) : 0
ReLU( 0) : 0
ReLU( 1) : 1
ReLU( 2) : 2
```

ReLU 함수를 그려보자

- 아래와 같은 코드로 이 함수를 시각화해 보자.
  - 이 함수의 입력값은 –6에서 6 사이의 값이다.

```
inputs = np.arange(-6, 6, .1)  # 입력값의 범위
outputs = ReLU(inputs)

plt.figure(figsize=(5, 3))
plt.plot(inputs, outputs, label='ReLU')
plt.hlines(0, -6, 6)           # 수평축의 범위
plt.vlines(0, 0, 6)            # 수직축의 범위
plt.title('ReLU',fontsize=12)
plt.show()
```



ReLU 함수를 그려보자

- 이러한 ReLU 함수 역시 약간의 문제점을 가지고 있는데, 음수 입력에 대해 무조건 출력이 0이 된다는 점이다.
- 상수 0의 기울기는 0이므로 음수 값에 대해서는 0을 기울기로 가진다.
- 이 문제를 **죽은 ReLU 문제**라고 하는데 이를 극복하기 위해 Leaky ReLU, Parametric ReLU, ELU(exponential linear unit), PReLU(parametric rectified linear unit) 등의 변형된 ReLU 함수가 많이 제안되었다.

요약

01 수학에서 기호를 사용하면 **명확성, 간결성, 일반화, 추상화, 의사소통**의 장점을 가진다.

02 **신경망의 학습 과정은 입력과 가중치를 곱하여 추정값을 내보낸 뒤, 오차를 계산**하고 **추정값과 목표값의 차이를 바탕으로 전체 신경망의 가중치를 갱신**하는 작업을 **반복**한다.

03 **오차 역전파 알고리즘**은 딥러닝의 핵심이 되는 알고리즘으로, 신경망의 출력 오차를 거꾸로 **전파**시켜 각 뉴런의 가중치를 조정하는 방식이다. 또한 신경망의 성능을 **최적화**하는 방법이다.

04 오차 역전파 알고리즘은 1950년대 말에 그 아이디어가 등장하였으나 기술적 한계를 극복하지 못하고 연구가 정체되었다. 그러나 2006년 이후에 기술적 한계를 다양한 방법으로 극복하면서 오늘날 딥러닝 기술의 핵심으로 부각되었다.

05 **계산 그래프**란 계산의 과정을 노드와 간선을 가지는 그래프로 나타내는 표현 방법으로, **오차 역전파 알고리즘**을 이해하는 데 유용한 도구이다.

06 계산 그래프에서 중간 노드가 가진 미분 값을 **국소적 미분값** 또는 **지역 기울기**라고 한다. 이 지역 기울기는 연쇄 법칙을 적용할 때 매우 유용한데, 이를 사용하여 계산 그래프의 전체 노드의 출력에 대하여 미치는 영향력을 구할 수 있다.

07 계단 함수는 **미분이 불가능한 지점이 있으며, 미분이 되는 곳에서도 미분치가 언제나 0**이다. 따라서 오차 역전파 방법에 적용하기가 어려우며, 모든 구간에서 미분이 가능한 **새로운 활성화 함수**가 필요하다.

08 **시그모이드 함수는 모든 구간에서 미분이 가능**하며 미분의 결과는 모든 구간에서 **연속**이다. 또한 함수의 미분은 원래의 함수를 이용하여 표현이 가능하다.

09 **시그모이드 함수**는 기울기 소식 문제와 높은 계산 비용으로 인하여 딥러닝 모델의 성능을 향상시키는 데 제약이 있었다. ReLU 함수는 이 문제를 극복하고 딥러닝 모델이 좋은 성능을 내는 데 기여하였으며, 이 성과에 힘입어 유사한 활성화 함수들이 출현하였다.